

Influência do Uso de Busca Linear Exata na Convergência de Métodos Acelerados de Gradiente Proximal

Orientador: Elias Salomão Helou Neto

Aluno: Gabriel Ligabô Baba

4 de junho de 2025

Resumo

1 Introdução e Justificativa

1.1 Introdução

Ao resolver numericamente um problema de otimização matemática, o algoritmo a ser utilizado deve ser escolhido baseado em considerações acerca do problema em mãos. Durante o processo de escolha de tal algoritmo numérico, devemos levar em conta a categoria de problema sendo resolvido (linear, cônico de segunda ordem, convexo, suave, inteiro, contínuo, etc.) e da informação disponível, também conhecida como oráculo, a cada passo do método (valor funcional, gradientes, hessianas, funções substitutas, minimizadores de relaxações, etc.). Outros fatores importantes também influenciam a escolha do método, tais como ambiente e plataforma computacional, tempo de computação disponível, precisão numérica necessária ou desejada, dimensões do problema (número de variáveis e tamanho do conjunto de dados), dentre outros.

Um caso de amplo interesse é quando temos problemas de reconstrução de imagens através da minimização de funções com a seguinte forma

$$\min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2 + g(\mathbf{x}), \quad (1)$$

onde $A \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$ e $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa e prox-amigável. Por prox-amigável, queremos dizer que o operador proximal de λg , para $\lambda \in \mathbb{R}_+$, é calculável em um tempo de computação razoável. A definição do operador proximal $\text{prox}_{\lambda g}(\mathbf{x})$ de λg em $\mathbf{x}$ é dado por

$$\text{prox}_{\lambda g}(\mathbf{x}) := \arg \min_{\mathbf{y} \in \mathbb{R}^n} \frac{1}{2} \|\mathbf{y} - \mathbf{x}\|_2^2 + \lambda g(\mathbf{y}).$$

Em reconstrução de imagens, o número n de variáveis é igual ao número de *pixels* da imagem e, portanto, muito grande, da ordem de centenas de milhares ou até na casa dos milhões. Problemas da forma (1) são úteis em problemas de tomografia computadorizada [7, 8, 9, 10], em remoção de ruído em imagens [11, 14, 15] e refoque de imagens desfocadas e com ruído [1, 2, 11]. De fato, este tipo de problema aparece com frequência em regularização variacional de problemas inversos lineares mal condicionados [3].




Figura 1: Esquerda: geometria da Transformada de Radon. Direita: Transformada de Radon da imagem à esquerda, exibida como uma imagem no plano $\theta \times t$.

1.2 Tomografia Computadorizada

Deixando de lado o desenvolvimento de detalhes técnicos da física subjacente, a situação em um tomógrafo leva a um modelo baseado na transformada de Radon [7, 9, 10] $\mathcal{R}[f]$ de $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, definida através de

$$\mathcal{R}[f](\theta, t) := \int_{\mathbb{R}} f \left(t \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix} + s \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix} \right) ds.$$

Veja a Figura 1 para uma ilustração.

A incógnita é a função f ao passo que os dados obtidos são os valores da transformada de Radon $\mathcal{R}[f]$. Uma vez que o tempo de coleta de dados é limitado e que na prática a função solução é buscada em um espaço de dimensão finita, o problema pode ser reduzido à solução (aproximada) de um sistema de equações lineares $R\mathbf{x} \approx \mathbf{r}$, onde $R \in \mathbb{R}^{m \times n}$ é uma matriz obtida a partir da discretização da transformada de Radon, que depende da base utilizada para descrever o espaço de funções e das condições geométricas de aquisição, $\mathbf{x} \in \mathbb{R}^n$ é o vetor desconhecido de coeficientes da combinação linear de elementos da base que resulta na solução do problema (i.e., a solução é $f = x_1 f_1 + x_2 f_2 + \dots + x_n f_n$ onde $\{f_1, f_2, \dots, f_n\}$ é a base para o espaço de funções onde a solução é buscada) e $\mathbf{r}$ é o vetor de dados coletados (sempre aproximado pois há erros sistemáticos de modelagem e ruído na aquisição dos

dados).

1.3 Justificativa

Uma vez que, graças à natureza da transformada de Radon, a matriz R sempre é mal condicionada e o lado direito $\mathbf{r}$ inevitavelmente contém ruído, a solução aproximada deve ser estabilizada através do uso de um termo de suavização, de forma que o modelo a ser resolvido possui a forma

$$\min_{\mathbf{x}} f(R\mathbf{x}, \mathbf{r}) + \gamma g(\mathbf{x}),$$

onde $f : \mathbb{R}^m \times \mathbb{R}^m \rightarrow \mathbb{R}$ é uma função que força a proximidade entre $R\mathbf{x}$ e $\mathbf{r}$, $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é uma função que força a suavidade da imagem resultante e $\gamma \in \mathbb{R}_+$ é um parâmetro que controla a suavidade imposta na solução do problema. Algoritmos de ϵ -subgradientes foram utilizados com sucesso em [6] e algoritmos acelerados de primeira ordem em [4, 5] para resolver modelos úteis da forma acima, portanto, esperamos que as técnicas a serem estudadas no presente projeto sejam ainda mais bem sucedidas nesta aplicação.

Objetivos

O objetivo do seguinte projeto de iniciação científica é estudar o uso de busca direcional exata no passo de máxima descida do método de gradiente-proximal acelerado conhecido como FISTA [1, 2] aplicado ao problema (1). Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) + g(\mathbf{x}), \quad (2)$$

onde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa e diferenciável e $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa.

Ademais, supomos que o gradiente de f é Lipschitz. Isto é, existe $L_f \geq 0$ tal que

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|_2 \leq L_f \|\mathbf{x} - \mathbf{y}\|_2$$

e que o operador proximal de λg pode ser calculado com relativa facilidade.

Para esta categoria de problemas, quando o número n de variáveis é muito

grande, um algoritmo candidato para a aplicação é o FISTA [1, 2]:

$$\begin{aligned}\mathbf{y}^{(k)} &= \text{prox}_{\lambda_k g}(\mathbf{x}^{(k)} - \lambda_k \nabla f(\mathbf{x}^{(k)})) \\ t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2} \\ \mathbf{x}^{(k+1)} &= \mathbf{y}^{(k)} + \frac{t_k - 1}{t_{k+1}}(\mathbf{y}^{(k)} - \mathbf{y}^{(k-1)}).\end{aligned}$$

Na formulação acima, λ_k pode ser mantido fixo, desde que suficientemente pequeno, ou determinado através de uma busca direcional acoplada a um critério de descida suficiente.

O principal objetivo do presente projeto é estudar o que ocorre quando, para o caso especial (1), o tamanho de passo é escolhido através de busca direcional exata. Observe que FISTA foi desenvolvido para o caso mais geral (2), onde a busca direcional exata é impossível. Para o caso em que f é uma função quadrática da forma

$$f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T Q \mathbf{x} - \mathbf{c}^T \mathbf{x},$$

entretanto, o tamanho de passo que minimiza a função a partir de $\mathbf{x}^{(k)}$ ao longo de uma direção de busca $\mathbf{d}^{(k)}$ pode ser calculado com esforço computacional relativamente baixo através da fórmula

$$\lambda_k = -\frac{\nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}}{(\mathbf{d}^{(k)})^T Q \mathbf{d}^{(k)}}.$$

Em métodos para minimizar apenas a função quadrática f , o cálculo de $Q\mathbf{d}^{(k)}$ pode ser reaproveitado ou vir de quantidades calculadas previamente. Este não parece ser o caso para algoritmos como FISTA, portanto, nossos objetivos são:

- Analisar experimentalmente o ganho de velocidade de convergência em número de iterações com o uso do passo exato com regularização baseada em variação total
- Avaliar o ganho de custo/benefício em tempo de computação entre o passo fixo e passo exato com regularização baseada em variação total
- Aplicar o método para o caso de reconstrução de imagens em tomografia com regularização baseada em variação total

- Repetir os estudos acima para o caso sem regularização (onde o cálculo de $Q\mathbf{d}^{(k)}$ não impõe dificuldade extra), mas desta vez levando em consideração a aplicabilidade do método de gradientes conjugados

Plano de Trabalho e Cronograma

Material e Metodologia

Esta seção descreve os dados utilizados na aplicação do método de reconstrução de imagem em tomografia computadorizada com regularização por variação total, além de apresentar os métodos empregados no desenvolvimento do projeto.

1.4 Material

1.5 Metodologia

Transformada de Radon

A tomografia computadorizada é um exemplo clássico de problema inverso, cujo objetivo é de determinar a estrutura interna de um objeto de maneira não invasiva. A ideia principal desse tipo de método baseia-se no fato de que enviar raios-x, gama, neutrinos, entre outros sobre objetos distintos gera coeficientes de atenuação diferentes [12]. Nesse processo, sensores medem a intensidade residual dos raios após atravessarem o objeto, e os dados coletados são utilizados para a reconstrução matemática precisa da anatomia interna original.

No entanto, apenas uma radiografia não é suficiente para se obter uma boa aproximação da estrutura interna de um objeto. Por isso, é necessário que o objeto seja radiografado em diversas direções, gerando múltiplas projeções. Essas múltiplas projeções, obtidas em diferentes ângulos, são matematicamente descritas pela Transformada de Radon [13] de uma função $f(x, y)$, sendo definida como uma integral de linha ao longo de uma reta inclinada em um ângulo θ .

Referências

Referências

- [1] Amir Beck e Marc Teboulle. “A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems”. Em: *SIAM Journal on Imaging Sciences* 2.1 (2009), pp. 183–202. DOI: 10.1137/080716542.
- [2] Amir Beck e Marc Teboulle. “Fast Gradient-Based Algorithms for Constrained Total Variation Image Denoising and Deblurring Problems”. Em: *IEEE Transactions on Image Processing* 18.11 (2009), pp. 2419–2434. DOI: 10.1109/TIP.2009.2028250.
- [3] Heinz W. Engl, Martin Hanke e Andreas Neubauer. *Regularization of Inverse Problems*. Dordrecht, Boston, London: Kluwer Academic Publishers, 2000.
- [4] Elias S. Helou e Lucas E. A. Simões. “ ϵ -Subgradient Algorithms for Bilevel Convex Optimization”. Em: *Inverse Problems* 33.5 (2017), p. 055020. DOI: 10.1088/1361-6420/aa6136.
- [5] Elias S. Helou, Marcelo V. W. Zibetti e Gabor T. Herman. “Fast Proximal Gradient Methods for Nonsmooth Convex Optimization for Tomographic Image Reconstruction”. Em: *Sensing and Imaging* 21.45 (2020). DOI: 10.1007/s11220-020-00309-z.
- [6] Elias Salomão Helou Neto e Álvaro Rodolfo De Pierro. “Incremental Subgradients for Constrained Convex Optimization: a Unified Framework and New Methods”. Em: *SIAM Journal on Optimization* 20.3 (2009), pp. 1547–1572. DOI: 10.1137/070711712. URL: <http://link.aip.org/link/?SJE/20/1547/1>.
- [7] Gabor T. Herman. *Image Reconstruction from Projections: The Fundamentals of Computerized Tomography*. Boston (MA): Academic Press, 1980.
- [8] Avinash C. Kak e Malcolm Slaney. *Principles of Computerized Tomographic Imaging*. New York: IEEE Press, 1988.
- [9] Frank Natterer. *The Mathematics of Computerized Tomography*. Chichester, New York, Brisbane, Toronto, Singapore: John Wiley & Sons Ltd, 1986.

- [10] Frank Natterer e Frank Wübbeling. *Mathematical Methods in Image Reconstruction*. Philadelphia (PA): SIAM, 2001.
- [11] Stanley Osher et al. “An Iterative Regularization Method for Total Variation-Based Image Restoration”. Em: *Multiscale Modeling & Simulation* 4.2 (2005), pp. 460–489. DOI: 10.1137/040605412.
- [12] Eric Todd Quinto. “An introduction to X-ray tomography and Radon transforms”. Em: *Proceedings of symposia in Applied Mathematics*. Vol. 63. 2006, p. 1.
- [13] Johann Radon. “On the determination of functions from their integral values along certain manifolds”. Em: *IEEE Transactions on Medical Imaging* 5.4 (1986), pp. 170–176. DOI: 10.1109/TMI.1986.4307775.
- [14] Leonid I. Rudin, Stanley Osher e Emad Fatemi. “Nonlinear Total Variation Based Noise Removal Algorithms”. Em: *Physica D: Nonlinear Phenomena* 60.1-4 (1992), pp. 259–268. DOI: 10.1016/0167-2789(92)90242-F. URL: <http://www.sciencedirect.com/science/article/B6TVK-46JYGGT-GH/2/f85f57585ec9af00a1a088d0b8e6d452>.
- [15] Eitan Tadmor, Suzanne Nezzar e Luminita Vese. “A Multiscale Image Representation Using Hierarchical (BV, L^2) Decompositions”. Em: *Multiscale Modeling & Simulation* 2.4 (2004), pp. 554–579. DOI: 10.1137/030600448.