

Influência do Uso de Busca Linear Exata na Convergência de Métodos Acelerados de Gradiente Proximal

Orientador: Elias Salomão Helou Neto

Aluno: Gabriel Ligabô Baba

9 de junho de 2025

Resumo

Métodos de otimização são peça-chave em reconstrução de imagens médicas, especialmente em tomografia computadorizada. Os dados adquiridos por esta técnica consistem em uma amostragem ruidosa da transformada de Radon, o que leva à necessidade da adição de termos de regularização ao modelo de otimização, para que assim o ruído contido nos dados não seja excessivamente amplificado na imagem reconstruída. Muitas das possíveis escolhas para o termo regularizador não são suaves, mas são convexas e prox-amigáveis, levando ao uso de algoritmos de otimização do tipo gradiente proximal acelerado. Este projeto aborda um ponto específico e pouco explorado: propomos substituir as estratégias de tamanho de passo usuais (e.g., passo fixo ou determinado por busca inexata com critério de descida suficiente) no algoritmo FISTA (Fast Iterative Shrinkage-Thresholding Algorithm). Em seu lugar, investigar-se-á o uso de uma busca linear exata para determinar o tamanho de passo. Especificamente, usaremos um termo de quadrados mínimos na parcela de consistência e calcularemos analiticamente o passo que minimiza tal parcela ao longo da direção de máxima descida. A meta é medir, de forma objetiva, como tal escolha afeta a convergência em iterações e o tempo de computação, além da qualidade de reconstrução em dados de tomografia computadorizada.

1 Introdução e Justificativa

1.1 Introdução

Ao resolver numericamente um problema de otimização matemática, o algoritmo a ser utilizado deve ser escolhido baseado em considerações acerca do problema em mãos. Durante o processo de escolha de tal algoritmo numérico, devemos levar em conta a categoria de problema sendo resolvido (linear, cônico de segunda ordem, convexo, suave, inteiro, contínuo, etc.) e da informação disponível, também conhecida como oráculo, a cada passo do método (valor funcional, gradientes, hessianas, funções substitutas, minimizadores de relaxações, etc.). Outros fatores importantes também influenciam a escolha do método, tais como ambiente e plataforma computacional, tempo de computação disponível, precisão numérica necessária ou desejada, dimensões do problema (número de variáveis e tamanho do conjunto de dados), dentre outros.

Um caso de amplo interesse é quando temos problemas de reconstrução de imagens através da minimização de funções com a seguinte forma

$$\min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2 + g(\mathbf{x}), \quad (1)$$

onde $A \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$ e $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa e prox-amigável. Por prox-amigável, queremos dizer que o operador proximal de λg , para $\lambda \in \mathbb{R}_+$, é calculável em um tempo de computação razoável. A definição do operador proximal $\text{prox}_{\lambda g}(\mathbf{x})$ de λg em $\mathbf{x}$ é dado por

$$\text{prox}_{\lambda g}(\mathbf{x}) := \arg \min_{\mathbf{y} \in \mathbb{R}^n} \frac{1}{2} \|\mathbf{y} - \mathbf{x}\|_2^2 + \lambda g(\mathbf{y}).$$

Em reconstrução de imagens, o número n de variáveis é igual ao número de *pixels* da imagem e, portanto, muito grande, da ordem de centenas de milhares ou até na casa dos milhões. Problemas da forma (1) são úteis para aplicações em tomografia computadorizada [7, 8, 9, 10], em remoção de ruído em imagens [11, 12, 13] e refoque de imagens desfocadas e com ruído [1, 2, 11]. De fato, este tipo de modelo aparece com frequência em regularização variacional de problemas inversos lineares mal condicionados [3].




Figura 1: Esquerda: geometria da Transformada de Radon. Direita: Transformada de Radon da imagem à esquerda, exibida como uma imagem no plano $\theta \times t$.

1.2 Tomografia Computadorizada

Deixando de lado o desenvolvimento de detalhes técnicos da física subjacente, a situação em um tomógrafo leva a um modelo baseado na transformada de Radon [7, 9, 10] $\mathcal{R}[f]$ de $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, definida através de

$$\mathcal{R}[f](\theta, t) := \int_{\mathbb{R}} f\left(t \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix} + s \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix}\right) ds.$$

Veja a Figura 1 para uma ilustração.

A incógnita é a função f , ao passo que os dados obtidos são os valores da transformada de Radon $\mathcal{R}[f]$. Uma vez que o tempo de coleta de dados é limitado e que na prática a função solução é buscada em um espaço de dimensão finita, o problema pode ser reduzido à solução (aproximada) de um sistema de equações lineares $R\mathbf{x} \approx \mathbf{r}$, onde $R \in \mathbb{R}^{m \times n}$ é uma matriz obtida a partir da discretização da transformada de Radon, que depende da base utilizada para descrever o espaço de funções e das condições geométricas de aquisição, $\mathbf{x} \in \mathbb{R}^n$ é o vetor desconhecido de coeficientes da combinação linear de elementos da base que resulta na solução do problema (i.e., a solução é $f = x_1 f_1 + x_2 f_2 + \dots + x_n f_n$ onde $\{f_1, f_2, \dots, f_n\}$ é a base para o espaço de funções onde a solução é buscada) e $\mathbf{r}$ é o vetor de dados coletados (sempre aproximado pois há erros sistemáticos de modelagem e ruído na aquisição dos

dados).

1.3 Justificativa

Uma vez que, graças à natureza da transformada de Radon, a matriz R sempre é mal condicionada e o lado direito $\mathbf{r}$ inevitavelmente contém ruído, a solução aproximada deve ser estabilizada através do uso de um termo de suavização, de modo que o modelo a ser resolvido possui a forma

$$\min_{\mathbf{x}} f(R\mathbf{x}, \mathbf{r}) + \gamma g(\mathbf{x}),$$

onde $f : \mathbb{R}^m \times \mathbb{R}^m \rightarrow \mathbb{R}$ é uma função que força a proximidade entre $R\mathbf{x}$ e $\mathbf{r}$, $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é uma função que força a suavidade da imagem resultante e $\gamma \in \mathbb{R}_+$ é um parâmetro que controla a suavidade imposta na solução do problema. Algoritmos de ϵ -subgradientes foram utilizados com sucesso em [6] e algoritmos acelerados de primeira ordem em [4, 5] para resolver modelos úteis da forma acima. Nenhum dos trabalhos mencionados levava em consideração a forma específica de quadrados mínimos regularizados que possui (1), portanto, esperamos que as técnicas a serem estudadas no presente projeto sejam ainda mais bem sucedidas nesta aplicação.

1.4 Materiais e métodos

A execução do presente projeto utilizará computadores comuns e *software* de código livre cuja disponibilidade é ampla e que são facilmente acessíveis. Nos dias de hoje, rotinas numéricas eficientes são facilmente utilizadas através de suas interfaces de programação para linguagens de alto nível, mesmo quando tais rotinas são implementadas em linguagens mais eficientes. Em particular, a linguagem Python reúne numerosas bibliotecas úteis no nosso contexto e, por este motivo, escolhemos esta linguagem para a execução da parte computacional do nosso projeto.

Por exemplo, para a computação de produtos matriz-vetor da forma $A\mathbf{x}$ ou $A^T\mathbf{y}$, onde A é a discretização da Transformada de Radon, temos a biblioteca ASTRA ou a desenvolvida pelo supervisor¹, ambas com suporte a GPU e com interfaces para Python. Para outras modalidades de reconstrução que podem vir a ser abordadas, sem a mesma prioridade de reconstrução tomográfica, no projeto, temos recuperação de imagens desfocadas, que costuma ser modelada

¹https://github.com/elias-helou/ray_tracing

através da convolução, cuja adjunta é a correlação, ambas implementadas eficientemente no pacote `scipy.signal`. Outra modalidade de reconstrução vem de técnicas de ressonância magnética, modelada através da transformada discreta de Fourier, que possui implementações em praticamente todas as linguagens de programação modernas.

Para a parcela de regularização, iremos utilizar duas opções, que são apropriadas para o problema de reconstrução de imagens. A primeira será $g(\mathbf{x}) = \gamma \|H\mathbf{x}\|_1$, onde $\gamma \geq 0$ é o parâmetro de regularização e H é uma transformada *wavelet* (que é ortonormal, auto-adjunta e computável eficientemente). Para esta regularização, o operador proximal de λg tem a forma fechada

$$\text{prox}_{\lambda g}(\mathbf{x}) = H^T \mathcal{S}_{\lambda\gamma}(H\mathbf{x}), \quad (2)$$

onde $\mathcal{S}_{\lambda\gamma}$ é o operador de *soft-thresholding*, dado por

$$(\mathcal{S}_\alpha(\mathbf{y}))_i = \begin{cases} y_i + \alpha & \text{se } y_i \leq -\alpha \\ 0 & \text{se } y_i \in (-\alpha, \alpha) \\ y_i - \alpha & \text{se } y_i \geq \alpha. \end{cases}$$

A segunda opção a ser testada é $g(\mathbf{x}) = \gamma TV(\mathbf{x})$, onde, novamente, $\gamma \geq 0$ é o parâmetro de regularização e, agora, TV é a variação total, dada por

$$TV(\mathbf{x}) = \sum_{i=1}^{\sqrt{n}} \sum_{j=1}^{\sqrt{n}} \sqrt{(x_{i,j} - x_{i-1,j})^2 + (x_{i,j} - x_{i,j-1})^2}.$$

No caso da variação total, não há uma forma fechada para o operador proximal, mas o algoritmo rápido fornecido em [2] pode ser implementado com facilidade e este algoritmo fornece uma aproximação suficientemente precisa de $\text{prox}_{\lambda\gamma TV}(\mathbf{x})$ com um número relativamente pequeno de iterações computacionalmente baratas.

A reconstrução de imagens requer dados. Para o caso de tomografia possuo aquisições de dados de microtomografia que podem ser utilizados neste projeto, além de dados sintéticos que podemos gerar com facilidade utilizando as mesmas ferramentas computacionais mencionadas acima. Os dados reais que temos parecem-se com os mostrados na Figura 2.




Figura 2: Dados de microtomografia obtidos no LNLS. À esquerda: uma radiografia de semente de maçã. À direita: sinograma (representação da Transformada de Radon no plano $\theta \times t$) de uma fatia, montado através de dados de 512 radiografias tomadas em ângulos distintos.

2 Objetivos

O objetivo do seguinte projeto de iniciação científica é estudar o uso de busca direcional exata no passo de máxima descida do método de gradiente-proximal acelerado conhecido como FISTA [1, 2] aplicado ao problema (1). Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) + g(\mathbf{x}), \quad (3)$$

onde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa e diferenciável e $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa.

Ademais, supomos que o gradiente de f é Lipschitz. Isto é, existe $L_f \geq 0$ tal que

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|_2 \leq L_f \|\mathbf{x} - \mathbf{y}\|_2$$

e que o operador proximal de λg pode ser calculado com relativa facilidade.

Para esta categoria de problemas, quando o número n de variáveis é muito grande, um algoritmo candidato para a aplicação é o FISTA [1, 2]:

$$\begin{aligned} \mathbf{y}^{(k)} &= \text{prox}_{\lambda_k g}(\mathbf{x}^{(k)} - \lambda_k \nabla f(\mathbf{x}^{(k)})) \\ t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2} \\ \mathbf{x}^{(k+1)} &= \mathbf{y}^{(k)} + \frac{t_k - 1}{t_{k+1}}(\mathbf{y}^{(k)} - \mathbf{y}^{(k-1)}). \end{aligned}$$

Na formulação acima, λ_k pode ser mantido fixo, desde que suficientemente pequeno, ou determinado através de uma busca direcional acoplada a um critério de descida suficiente.

O principal objetivo do presente projeto é estudar o que ocorre quando, para o caso especial (1), o tamanho de passo é escolhido através de busca direcional exata. Observe que FISTA foi desenvolvido para o caso mais geral (3), onde a busca direcional exata é impossível. Para o caso em que f é uma função quadrática da forma

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} - \mathbf{c}^T \mathbf{x},$$

entretanto, o tamanho de passo que minimiza a função a partir de $\mathbf{x}^{(k)}$ ao longo de uma direção de busca $\mathbf{d}^{(k)}$ pode ser calculado com esforço computacional relativamente baixo através da fórmula

$$\lambda_k = - \frac{\nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}}{(\mathbf{d}^{(k)})^T Q \mathbf{d}^{(k)}}.$$

Em métodos para minimizar apenas a função quadrática f , o cálculo de $Q\mathbf{d}^{(k)}$ pode ser reaproveitado posteriormente ou vir de quantidades calculadas previamente. Este não parece ser o caso para algoritmos como FISTA, portanto, nossos objetivos são:

- Analisar experimentalmente o ganho de velocidade de convergência em número de iterações com o uso do passo exato com regularização baseada em variação total
- Avaliar o ganho de custo/benefício em tempo de computação entre o passo fixo e passo exato com regularização baseada em variação total
- Aplicar o método para o caso de reconstrução de imagens em tomografia com regularização baseada em variação total
- Repetir os estudos acima para o caso sem regularização (onde o cálculo de $Q\mathbf{d}^{(k)}$ não impõe custo computacional significativo), mas desta vez levando em consideração a aplicabilidade do método de gradientes conjugados

3 Plano de Trabalho e Cronograma

Considerando o período de 12 meses, foram definidas as seguintes atividades e seus respectivos períodos de execução:

- A1 **Revisão e Acompanhamento da Literatura (Meses 1-12):** Atividade contínua para contextualizar o projeto e acompanhar pesquisas relevantes.
- A2 **Revisão Teórica e Fundamentos (Meses 1-2):** Estudo dos conceitos de otimização, regularização por Variação Total e Tomografia Computadorizada.
- A3 **Implementação (Meses 3-5):** Implementação do algoritmo FISTA com as estratégias de passo fixo, busca direcional com critério de descida suficiente e passo exato.
- A4 **Análise Experimental com Regularização (Meses 6-8):** Análise comparativa da convergência e do custo computacional na reconstrução de imagens com Variação Total.
- A5 **Análise Experimental sem Regularização (Mês 9):** Comparação do método com o de Gradientes Conjugados no problema de mínimos quadrados.
- A6 **Aplicação e Análise de Qualidade (Mês 10):** Aplicação do método em dados de tomografia e análise da qualidade da reconstrução final.
- A7 **Conclusão e Relatório Final (Meses 11-12):** Consolidação dos resultados, elaboração das conclusões e redação do documento final.

Referências

- [1] Amir Beck e Marc Teboulle. “A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems”. Em: *SIAM Journal on Imaging Sciences* 2.1 (2009), pp. 183–202. DOI: 10.1137/080716542.

Atividade	Mês											
	1	2	3	4	5	6	7	8	9	10	11	12
A1: Revisão Contínua	•	•	•	•	•	•	•	•	•	•	•	•
A2: Revisão Teórica	•	•										
A3: Implementação			•	•	•							
A4: Análise (c/ Reg.)						•	•	•				
A5: Análise (s/ Reg.)									•			
A6: Aplicação e Análise										•		
A7: Relatório Final											•	•

Tabela 1: Cronograma de execução do projeto detalhado por mês.

- [2] Amir Beck e Marc Teboulle. “Fast Gradient-Based Algorithms for Constrained Total Variation Image Denoising and Deblurring Problems”. Em: *IEEE Transactions on Image Processing* 18.11 (2009), pp. 2419–2434. DOI: 10.1109/TIP.2009.2028250.
- [3] Heinz W. Engl, Martin Hanke e Andreas Neubauer. *Regularization of Inverse Problems*. Dordrecht, Boston, London: Kluwer Academic Publishers, 2000.
- [4] Elias S. Helou e Lucas E. A. Simões. “ ϵ -Subgradient Algorithms for Bilevel Convex Optimization”. Em: *Inverse Problems* 33.5 (2017), p. 055020. DOI: 10.1088/1361-6420/aa6136.
- [5] Elias S. Helou, Marcelo V. W. Zibetti e Gabor T. Herman. “Fast Proximal Gradient Methods for Nonsmooth Convex Optimization for Tomographic Image Reconstruction”. Em: *Sensing and Imaging* 21.45 (2020). DOI: 10.1007/s11220-020-00309-z.
- [6] Elias Salomão Helou Neto e Álvaro Rodolfo De Pierro. “Incremental Subgradients for Constrained Convex Optimization: a Unified Framework and New Methods”. Em: *SIAM Journal on Optimization* 20.3 (2009), pp. 1547–1572. DOI: 10.1137/070711712. URL: <http://link.aip.org/link/?SJE/20/1547/1>.
- [7] Gabor T. Herman. *Image Reconstruction from Projections: The Fundamentals of Computerized Tomography*. Boston (MA): Academic Press, 1980.
- [8] Avinash C. Kak e Malcolm Slaney. *Principles of Computerized Tomographic Imaging*. New York: IEEE Press, 1988.

- [9] Frank Natterer. *The Mathematics of Computerized Tomography*. Chichester, New York, Brisbane, Toronto, Singapore: John Wiley & Sons Ltd, 1986.
- [10] Frank Natterer e Frank Wübbeling. *Mathematical Methods in Image Reconstruction*. Philadelphia (PA): SIAM, 2001.
- [11] Stanley Osher et al. “An Iterative Regularization Method for Total Variation-Based Image Restoration”. Em: *Multiscale Modeling & Simulation* 4.2 (2005), pp. 460–489. DOI: 10.1137/040605412.
- [12] Leonid I. Rudin, Stanley Osher e Emad Fatemi. “Nonlinear Total Variation Based Noise Removal Algorithms”. Em: *Physica D: Nonlinear Phenomena* 60.1-4 (1992), pp. 259–268. DOI: 10.1016/0167-2789(92)90242-F. URL: <http://www.sciencedirect.com/science/article/B6TVK-46JYGGT-GH/2/f85f57585ec9af00a1a088d0b8e6d452>.
- [13] Eitan Tadmor, Suzanne Nezzar e Luminita Vese. “A Multiscale Image Representation Using Hierarchical (BV, L^2) Decompositions”. Em: *Multiscale Modeling & Simulation* 2.4 (2004), pp. 554–579. DOI: 10.1137/030600448.