

Influência do Uso de Busca Linear Exata na Convergência de Métodos Acelerados de Gradiente Proximal

Orientador: Elias Salomão Helou Neto

Aluno: Gabriel Ligabô Baba

6 de junho de 2025

Resumo

Métodos de otimização são peça-chave em reconstrução de imagens médicas, especialmente em tomografia computadorizada. Os dados adquiridos por esta técnica consistem em uma amostragem ruidosa da transformada de Radon, o que leva à necessidade da adição de termos de regularização ao modelo de otimização, para que assim o ruído contido nos dados não seja excessivamente amplificado na imagem reconstruída. Muitas das possíveis escolhas para o termo regularizador não são suaves, mas são convexas e prox-amigáveis, levando ao uso de algoritmos de otimização do tipo gradiente proximal acelerado. Este projeto aborda um ponto específico e pouco explorado: propomos substituir as estratégias de tamanho de passo usuais (e.g., passo fixo ou determinado por busca inexata com critério de descida suficiente) no algoritmo FISTA (Fast Iterative Shrinkage-Thresholding Algorithm). Em seu lugar, investigar-se-á o uso de uma busca linear exata para determinar o tamanho de passo. Especificamente, usaremos um termo de quadrados mínimos na parcela de consistência e calcularemos analiticamente o passo que minimiza tal parcela ao longo da direção de máxima descida. A meta é medir, de forma objetiva, como tal escolha afeta a convergência em iterações e o tempo de computação, além da qualidade de reconstrução em dados de tomografia computadorizada.

1 Introdução e Justificativa

1.1 Introdução

Ao resolver numericamente um problema de otimização matemática, o algoritmo a ser utilizado deve ser escolhido baseado em considerações acerca do problema em mãos. Durante o processo de escolha de tal algoritmo numérico, devemos levar em conta a categoria de problema sendo resolvido (linear, cônico de segunda ordem, convexo, suave, inteiro, contínuo, etc.) e da informação disponível, também conhecida como oráculo, a cada passo do método (valor funcional, gradientes, hessianas, funções substitutas, minimizadores de relaxações, etc.). Outros fatores importantes também influenciam a escolha do método, tais como ambiente e plataforma computacional, tempo de computação disponível, precisão numérica necessária ou desejada, dimensões do problema (número de variáveis e tamanho do conjunto de dados), dentre outros.

Um caso de amplo interesse é quando temos problemas de reconstrução de imagens através da minimização de funções com a seguinte forma

$$\min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2 + g(\mathbf{x}), \quad (1)$$

onde $A \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$ e $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa e prox-amigável. Por prox-amigável, queremos dizer que o operador proximal de λg , para $\lambda \in \mathbb{R}_+$, é calculável em um tempo de computação razoável. A definição do operador proximal $\text{prox}_{\lambda g}(\mathbf{x})$ de λg em $\mathbf{x}$ é dado por

$$\text{prox}_{\lambda g}(\mathbf{x}) := \arg \min_{\mathbf{y} \in \mathbb{R}^n} \frac{1}{2} \|\mathbf{y} - \mathbf{x}\|_2^2 + \lambda g(\mathbf{y}).$$

Em reconstrução de imagens, o número n de variáveis é igual ao número de *pixels* da imagem e, portanto, muito grande, da ordem de centenas de milhares ou até na casa dos milhões. Problemas da forma (1) são úteis em problemas de tomografia computadorizada [7, 8, 9, 10], em remoção de ruído em imagens [11, 14, 15] e refoque de imagens desfocadas e com ruído [1, 2, 11]. De fato, este tipo de problema aparece com frequência em regularização variacional de problemas inversos lineares mal condicionados [3].




Figura 1: Esquerda: geometria da Transformada de Radon. Direita: Transformada de Radon da imagem à esquerda, exibida como uma imagem no plano $\theta \times t$.

1.2 Tomografia Computadorizada

Deixando de lado o desenvolvimento de detalhes técnicos da física subjacente, a situação em um tomógrafo leva a um modelo baseado na transformada de Radon [7, 9, 10] $\mathcal{R}[f]$ de $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, definida através de

$$\mathcal{R}[f](\theta, t) := \int_{\mathbb{R}} f\left(t \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix} + s \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix}\right) ds.$$

Veja a Figura 1 para uma ilustração.

A incógnita é a função f ao passo que os dados obtidos são os valores da transformada de Radon $\mathcal{R}[f]$. Uma vez que o tempo de coleta de dados é limitado e que na prática a função solução é buscada em um espaço de dimensão finita, o problema pode ser reduzido à solução (aproximada) de um sistema de equações lineares $R\mathbf{x} \approx \mathbf{r}$, onde $R \in \mathbb{R}^{m \times n}$ é uma matriz obtida a partir da discretização da transformada de Radon, que depende da base utilizada para descrever o espaço de funções e das condições geométricas de aquisição, $\mathbf{x} \in \mathbb{R}^n$ é o vetor desconhecido de coeficientes da combinação linear de elementos da base que resulta na solução do problema (i.e., a solução é $f = x_1 f_1 + x_2 f_2 + \dots + x_n f_n$ onde $\{f_1, f_2, \dots, f_n\}$ é a base para o espaço de funções onde a solução é buscada) e $\mathbf{r}$ é o vetor de dados coletados (sempre aproximado pois há erros sistemáticos de modelagem e ruído na aquisição dos

dados).

1.3 Justificativa

Uma vez que, graças à natureza da transformada de Radon, a matriz R sempre é mal condicionada e o lado direito $\mathbf{r}$ inevitavelmente contém ruído, a solução aproximada deve ser estabilizada através do uso de um termo de suavização, de modo que o modelo a ser resolvido possui a forma

$$\min_{\mathbf{x}} f(R\mathbf{x}, \mathbf{r}) + \gamma g(\mathbf{x}),$$

onde $f : \mathbb{R}^m \times \mathbb{R}^m \rightarrow \mathbb{R}$ é uma função que força a proximidade entre $R\mathbf{x}$ e $\mathbf{r}$, $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é uma função que força a suavidade da imagem resultante e $\gamma \in \mathbb{R}_+$ é um parâmetro que controla a suavidade imposta na solução do problema. Algoritmos de ϵ -subgradientes foram utilizados com sucesso em [6] e algoritmos acelerados de primeira ordem em [4, 5] para resolver modelos úteis da forma acima, portanto, esperamos que as técnicas a serem estudadas no presente projeto sejam ainda mais bem sucedidas nesta aplicação.

Objetivos

O objetivo do seguinte projeto de iniciação científica é estudar o uso de busca direcional exata no passo de máxima descida do método de gradiente-proximal acelerado conhecido como FISTA [1, 2] aplicado ao problema (1). Considere o problema

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) + g(\mathbf{x}), \quad (2)$$

onde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa e diferenciável e $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa.

Ademais, supomos que o gradiente de f é Lipschitz. Isto é, existe $L_f \geq 0$ tal que

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|_2 \leq L_f \|\mathbf{x} - \mathbf{y}\|_2$$

e que o operador proximal de λg pode ser calculado com relativa facilidade.

Para esta categoria de problemas, quando o número n de variáveis é muito

grande, um algoritmo candidato para a aplicação é o FISTA [1, 2]:

$$\begin{aligned}\mathbf{y}^{(k)} &= \text{prox}_{\lambda_k g}(\mathbf{x}^{(k)} - \lambda_k \nabla f(\mathbf{x}^{(k)})) \\ t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2} \\ \mathbf{x}^{(k+1)} &= \mathbf{y}^{(k)} + \frac{t_k - 1}{t_{k+1}}(\mathbf{y}^{(k)} - \mathbf{y}^{(k-1)}).\end{aligned}$$

Na formulação acima, λ_k pode ser mantido fixo, desde que suficientemente pequeno, ou determinado através de uma busca direcional acoplada a um critério de descida suficiente.

O principal objetivo do presente projeto é estudar o que ocorre quando, para o caso especial (1), o tamanho de passo é escolhido através de busca direcional exata. Observe que FISTA foi desenvolvido para o caso mais geral (2), onde a busca direcional exata é impossível. Para o caso em que f é uma função quadrática da forma

$$f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T Q \mathbf{x} - \mathbf{c}^T \mathbf{x},$$

entretanto, o tamanho de passo que minimiza a função a partir de $\mathbf{x}^{(k)}$ ao longo de uma direção de busca $\mathbf{d}^{(k)}$ pode ser calculado com esforço computacional relativamente baixo através da fórmula

$$\lambda_k = -\frac{\nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}}{(\mathbf{d}^{(k)})^T Q \mathbf{d}^{(k)}}.$$

Em métodos para minimizar apenas a função quadrática f , o cálculo de $Q\mathbf{d}^{(k)}$ pode ser reaproveitado ou vir de quantidades calculadas previamente. Este não parece ser o caso para algoritmos como FISTA, portanto, nossos objetivos são:

- Analisar experimentalmente o ganho de velocidade de convergência em número de iterações com o uso do passo exato com regularização baseada em variação total
- Avaliar o ganho de custo/benefício em tempo de computação entre o passo fixo e passo exato com regularização baseada em variação total
- Aplicar o método para o caso de reconstrução de imagens em tomografia com regularização baseada em variação total

- Repetir os estudos acima para o caso sem regularização (onde o cálculo de $Qd^{(k)}$ não impõe custo computacional significativo), mas desta vez levando em consideração a aplicabilidade do método de gradientes conjugados

Plano de Trabalho e Cronograma

Cronograma

Considerando o período de 12 meses, foram definidas as seguintes atividades e seus respectivos períodos de execução:

- A1 **Revisão e Acompanhamento da Literatura (Meses 1-12):** Atividade contínua para contextualizar o projeto e acompanhar pesquisas relevantes.
- A2 **Revisão Teórica e Fundamentos (Meses 1-2):** Estudo dos conceitos de otimização, regularização por Variação Total e Tomografia Computadorizada.
- A3 **Implementação (Meses 3-5):** Implementação do algoritmo FISTA com as estratégias de passo fixo, busca direcional com critério de descida suficiente e passo exato.
- A4 **Análise Experimental com Regularização (Meses 6-8):** Análise comparativa da convergência e do custo computacional na reconstrução de imagens com Variação Total.
- A5 **Análise Experimental sem Regularização (Mês 9):** Comparação do método com o de Gradientes Conjugados no problema de mínimos quadrados.
- A6 **Aplicação e Análise de Qualidade (Mês 10):** Aplicação do método em dados de tomografia e análise da qualidade da reconstrução final.
- A7 **Conclusão e Relatório Final (Meses 11-12):** Consolidação dos resultados, elaboração das conclusões e redação do documento final.

Atividade	Mês											
	1	2	3	4	5	6	7	8	9	10	11	12
A1: Revisão Contínua	•	•	•	•	•	•	•	•	•	•	•	•
A2: Revisão Teórica	•	•										
A3: Implementação			•	•	•							
A4: Análise (c/ Reg.)						•	•	•				
A5: Análise (s/ Reg.)									•			
A6: Aplicação e Análise										•		
A7: Relatório Final											•	•

Tabela 1: Cronograma de execução do projeto detalhado por mês.

1.4 Material

1.5 Metodologia

Transformada de Radon

A tomografia computadorizada é um exemplo clássico de problema inverso, cujo objetivo é de determinar a estrutura interna de um objeto de maneira não invasiva. A ideia principal desse tipo de método baseia-se no fato de que enviar raios-x, gama, neutrinos, entre outros sobre objetos distintos gera coeficientes de atenuação diferentes [12]. Nesse processo, sensores medem a intensidade residual dos raios após atravessarem o objeto, e os dados coletados são utilizados para a reconstrução matemática precisa da anatomia interna original.

No entanto, apenas uma radiografia não é suficiente para se obter uma boa aproximação da estrutura interna de um objeto. Por isso, é necessário que o objeto seja radiografado em diversas direções, gerando múltiplas projeções. Essas múltiplas projeções, obtidas em diferentes ângulos, são matematicamente descritas pela Transformada de Radon [13] de uma função $f(x, y)$, sendo definida como uma integral de linha ao longo de uma reta inclinada em um ângulo θ .

Referências

Referências

- [1] Amir Beck e Marc Teboulle. “A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems”. Em: *SIAM Journal on Imaging Sciences* 2.1 (2009), pp. 183–202. DOI: 10.1137/080716542.
- [2] Amir Beck e Marc Teboulle. “Fast Gradient-Based Algorithms for Constrained Total Variation Image Denoising and Deblurring Problems”. Em: *IEEE Transactions on Image Processing* 18.11 (2009), pp. 2419–2434. DOI: 10.1109/TIP.2009.2028250.
- [3] Heinz W. Engl, Martin Hanke e Andreas Neubauer. *Regularization of Inverse Problems*. Dordrecht, Boston, London: Kluwer Academic Publishers, 2000.
- [4] Elias S. Helou e Lucas E. A. Simões. “ ϵ -Subgradient Algorithms for Bilevel Convex Optimization”. Em: *Inverse Problems* 33.5 (2017), p. 055020. DOI: 10.1088/1361-6420/aa6136.
- [5] Elias S. Helou, Marcelo V. W. Zibetti e Gabor T. Herman. “Fast Proximal Gradient Methods for Nonsmooth Convex Optimization for Tomographic Image Reconstruction”. Em: *Sensing and Imaging* 21.45 (2020). DOI: 10.1007/s11220-020-00309-z.
- [6] Elias Salomão Helou Neto e Álvaro Rodolfo De Pierro. “Incremental Subgradients for Constrained Convex Optimization: a Unified Framework and New Methods”. Em: *SIAM Journal on Optimization* 20.3 (2009), pp. 1547–1572. DOI: 10.1137/070711712. URL: <http://link.aip.org/link/?SJE/20/1547/1>.
- [7] Gabor T. Herman. *Image Reconstruction from Projections: The Fundamentals of Computerized Tomography*. Boston (MA): Academic Press, 1980.
- [8] Avinash C. Kak e Malcolm Slaney. *Principles of Computerized Tomographic Imaging*. New York: IEEE Press, 1988.
- [9] Frank Natterer. *The Mathematics of Computerized Tomography*. Chichester, New York, Brisbane, Toronto, Singapore: John Wiley & Sons Ltd, 1986.

- [10] Frank Natterer e Frank Wübbeling. *Mathematical Methods in Image Reconstruction*. Philadelphia (PA): SIAM, 2001.
- [11] Stanley Osher et al. “An Iterative Regularization Method for Total Variation-Based Image Restoration”. Em: *Multiscale Modeling & Simulation* 4.2 (2005), pp. 460–489. DOI: 10.1137/040605412.
- [12] Eric Todd Quinto. “An introduction to X-ray tomography and Radon transforms”. Em: *Proceedings of symposia in Applied Mathematics*. Vol. 63. 2006, p. 1.
- [13] Johann Radon. “On the determination of functions from their integral values along certain manifolds”. Em: *IEEE Transactions on Medical Imaging* 5.4 (1986), pp. 170–176. DOI: 10.1109/TMI.1986.4307775.
- [14] Leonid I. Rudin, Stanley Osher e Emad Fatemi. “Nonlinear Total Variation Based Noise Removal Algorithms”. Em: *Physica D: Nonlinear Phenomena* 60.1-4 (1992), pp. 259–268. DOI: 10.1016/0167-2789(92)90242-F. URL: <http://www.sciencedirect.com/science/article/B6TVK-46JYGGT-GH/2/f85f57585ec9af00a1a088d0b8e6d452>.
- [15] Eitan Tadmor, Suzanne Nezzar e Luminita Vese. “A Multiscale Image Representation Using Hierarchical (BV, L^2) Decompositions”. Em: *Multiscale Modeling & Simulation* 2.4 (2004), pp. 554–579. DOI: 10.1137/030600448.