

UNIVERSIDADE DE SÃO PAULO  
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE  
COMPUTAÇÃO

DEPARTAMENTO DE MATEMÁTICA APLICADA E ESTATÍSTICA

RELATÓRIO CIENTÍFICO SEMESTRAL

---

**Influência do Uso de Busca Linear Exata na  
Convergência de Métodos Acelerados de Gradiente  
Proximal**

---

LINHA DE FOMENTO: BOLSA NO PAÍS - REGULAR - INICIAÇÃO CIENTÍFICA

**Processo FAPESP:** 2025/12023-2

**Período de vigência:** 01/09/2025 a 31/08/2026

*Bolsista:*  
Gabriel Ligabô Baba

*Orientador:*  
Elias Salomão Helou Neto

São Carlos – SP  
21 de fevereiro de 2026

# Sumário

|          |                                                                       |           |
|----------|-----------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introdução</b>                                                     | <b>2</b>  |
| <b>2</b> | <b>Fundamentação Matemática</b>                                       | <b>2</b>  |
| 2.1      | ISTA e FISTA . . . . .                                                | 4         |
| <b>3</b> | <b>Resultados</b>                                                     | <b>5</b>  |
| 3.1      | Métodos sem Regularização para <i>Deblurring</i> de Imagens . . . . . | 5         |
| 3.2      | Métodos com Regularização para Reconstrução de Imagens . . . . .      | 13        |
| <b>4</b> | <b>Conclusão</b>                                                      | <b>21</b> |

# 1 Introdução

Métodos de otimização são peça-chave em reconstrução de imagens médicas, especialmente em tomografia computadorizada. Os dados adquiridos por esta técnica consistem em uma amostragem ruidosa da transformada de Radon, o que leva à necessidade da adição de termos de regularização ao modelo de otimização, para que assim o ruído contido nos dados não seja excessivamente amplificado na imagem reconstruída. Muitas das possíveis escolhas para o termo regularizador não são suaves, mas são convexas e prox-amigáveis, levando ao uso de algoritmos de otimização do tipo gradiente proximal acelerado. Este projeto aborda um ponto específico e pouco explorado: propomos substituir as estratégias de tamanho de passo usuais (e.g., passo fixo ou determinado por busca inexata com critério de descida suficiente) no algoritmo FISTA (Fast Iterative Shrinkage-Thresholding Algorithm). Em seu lugar, investigar-se-á o uso de uma busca linear exata para determinar o tamanho de passo. Especificamente, usaremos um termo de quadrados mínimos na parcela de consistência e calcularemos analiticamente o passo que minimiza tal parcela ao longo da direção de máxima descida. A meta é medir, de forma objetiva, como tal escolha afeta a convergência em iterações e o tempo de computação, além da qualidade de reconstrução em dados de tomografia computadorizada. Os experimentos iniciais, detalhados neste relatório, utilizam problemas de deblurring de imagens para testar a eficiência computacional e a estabilidade desses métodos antes de sua aplicação em dados de tomografia computadorizada, buscando medir o impacto na taxa de convergência e na qualidade da reconstrução final.

## 2 Fundamentação Matemática

**Definição 1.** Um subconjunto  $X \subset \mathbb{R}^n$  é dito convexo se, para todo  $x, y \in X$  e  $\lambda \in [0, 1]$ , ele satisfaz que:

$$\lambda x + (1 - \lambda)y$$

também pertence a  $X$ .

**Definição 2.** Seja  $X \subset \mathbb{R}^n$ . Seja  $f : X \rightarrow \mathbb{R}$ ,  $f$  é dita convexa se, para quaisquer  $x, y \in X$  e  $\lambda \in [0, 1]$  temos:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

As funções convexas nos dão algumas propriedades fundamentais, como as seguintes:

**Proposição 1.** *Seja  $f$  uma função de classe  $C^1$ . Então  $f$  é convexa em  $X$ , se e somente se, para todo  $x, y \in X$*

$$f(y) \geq f(x) + \nabla f(x)^T(y - x)$$

Em outras palavras, isso significa que a aproximação de primeira ordem de Taylor sempre subestima o valor real da função.

**Proposição 2.** *Seja  $f$  uma função de classe  $C^2$ . Seja  $X \subset \mathbb{R}^n$ , então  $f$  é convexa se e somente se, para todo  $x \in X$ :*

$$\nabla^2 f(x) \geq 0$$

**Definição 3.** *Dizemos que um vetor  $g \in \mathbb{R}^n$ , onde  $X$  é convexo, é um subgradiente de  $f : X \rightarrow \mathbb{R}$  convexa em um ponto  $x \in X$  se, para todo  $y \in X$  a seguinte desigualdade for satisfeita:*

$$f(y) \geq f(x) + g^T(y - x)$$

Em outras palavras,  $g$  define um hiperplano de suporte para o epígrafo de  $f$  no ponto  $(x, f(x))$ . Se  $f$  for diferenciável, então o subgradiente é o próprio gradiente da função.

**Observação 1.** *O epígrafo de uma função é definido como  $\text{epi}(f) = \{(x, y) : x \in \mathbb{R}^n, y \in \mathbb{R}, f(x) \leq y\}$*

**Definição 4.** *O conjunto de todos os subgradientes em um ponto  $x \in X$  é chamado de subdiferencial de  $f$  em  $x$ . A notação usada é:*

$$\partial f(x) = \{g \in \mathbb{R}^n : g^T(y - x) \leq f(y) - f(x), \forall y \in X\}$$

**Definição 5.** *Seja  $f : X \rightarrow \mathbb{R}$  uma função convexa. Definimos o operador proximal como sendo:*

$$\text{prox}_f(v) = \arg \min_{x \in X} \{f(x) + \frac{1}{2} \|x - v\|_2^2\}$$

A função  $f$  também pode ser multiplicada por uma constante  $\lambda > 0$ . Então o operador proximal fica:

$$\text{prox}_{\lambda f}(v) = \arg \min_{x \in X} \{f(x) + \frac{1}{2\lambda} \|x - v\|_2^2\}$$

**Definição 6.** Uma função  $f$  é dita  $L_f$ -suave se seu gradiente é Lipschitz contínuo com parâmetro  $L_f$ . Isto é:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L_f \|x - y\|_2$$

**Proposição 3.** No problema de mínimos quadrados definido por  $f(x) = \frac{1}{2} \|Ax - b\|_2^2$ , o tamanho de passo que minimiza a função ao longo da direção  $d_k$  é dado por:

$$\lambda_k = -\frac{\nabla f(x_k)^T d_k}{d_k^T Q d_k}$$

, onde  $Q = A^T A$

## 2.1 ISTA e FISTA

Quando estamos lidando com o problema compósito:

$$\min F(x) = f(x) + \gamma g(x)$$

onde:

$f(x)$  é uma função suave e convexa

$g(x)$  é uma função convexa não suave.

Uma possível forma de resolvê-lo é utilizando um método chamado de ISTA (*Iterative Shrinkage-Thresholding Algorithm*). A ideia por trás deste método, é aproveitar da suavidade de  $f$  para realizar um passo da descida do gradiente e, em seguida, corrigir o efeito da parte não diferenciável via operador proximal. Então fazemos:

---

### Algorithm 1 ISTA

---

- 1: **Entrada:**  $x_0 \in \mathbb{R}^n$ , passo  $\lambda > 0$ .
  - 2: **for**  $k = 0, 1, 2, \dots$  **do**
  - 3:      $x_{k+1} = \text{prox}_{\gamma \lambda g}(x_k - \lambda \nabla f(x_k))$
  - 4: **end for**
  - 5: **Retorno:** Solução aproximada  $x^*$ .
-

Uma variação mais eficiente é o FISTA (*Fast Iterative Shrinkage-Thresholding Algorithm*) [1], que utiliza o momento de Nesterov para acelerar a convergência.

---

**Algorithm 2** FISTA

---

- 1: **Entrada:**  $x_0 \in \mathbb{R}^n$ ,  $\lambda > 0$ .
  - 2: **Inicialização:**  $y_1 = x_0$ ,  $t_1 = 1$ .
  - 3: **for**  $k = 1, 2, \dots$  **do**
  - 4:      $x_k = \text{prox}_{\gamma\lambda g}(y_k - \lambda \nabla f(y_k))$
  - 5:      $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$
  - 6:      $y_{k+1} = x_k + \left(\frac{t_k - 1}{t_{k+1}}\right)(x_k - x_{k-1})$
  - 7: **end for**
  - 8: **Retorno:** Solução aproximada  $x^*$ .
- 

Um dos casos que será foco deste trabalho, é a utilização de  $g(x) = \|Hx\|_1$ , onde  $H$  é uma transformada *wavelet* ortonormal auto-adjunta. Neste caso, o operador proximal é facilmente computável, tendo fórmula fechada dada por:

$$\text{prox}_{\lambda\gamma g}(x) = H^T \mathcal{S}_{\lambda\gamma}(Hx)$$

onde  $\mathcal{S}_{\lambda\gamma}$  é o operador de *soft-thresholding*.

Um outro caso de interesse é quando  $g(x) = TV(x)$ , onde  $x \in \mathbb{R}^{m \times n}$ :

$$TV(x) = \sum_{i=1}^{m-1} \sum_{j=1}^{n-1} \sqrt{(x_{i,j} - x_{i+1,j})^2 + (x_{i,j} - x_{i,j+1})^2} + \sum_{i=1}^{m-1} |x_{i,n} - x_{i+1,n}| + \sum_{j=1}^{n-1} |x_{m,j} - x_{m,j+1}|$$

Neste caso, não existe forma fechada para o cálculo do operador proximal, mas o algoritmo rápido apresentado em [2] será implementado na linguagem python.

## 3 Resultados

### 3.1 Métodos sem Regularização para *Deblurring* de Imagens

Nessa etapa do projeto, comparamos diversos métodos: máxima descida com passo fixo (MDPF), máxima descida com busca linear exata (MDBE), método de Nesterov com passo fixo, método de Nesterov com critério de descida suficiente

(com *backtracking*), método de Nesterov com busca linear exata e gradientes conjugados para reconstrução de imagens borradas. O objetivo é:

$$\min_x \|Ax - b\|_2^2$$

onde  $A$  representa um operador de convolução (responsável pelo *blur*),  $x$  a imagem original a ser recuperada e  $b$  a imagem borrada.

Esses métodos foram comparados em termos de iterações e tempo de convergência visando analisar a influência do uso da busca linear exata. Implementamos todos os métodos em linguagem de programação Python com o uso de bibliotecas como Scipy, Numpy e Matplotlib. A imagem a ser recuperada foi a *coffee* da biblioteca *scikit-image*.

Inicialmente, foi utilizado um *grid search* para encontrar o melhor parâmetro de tamanho de passo, conforme apresentado na Figura 1:




Figura 1: Análise de tamanho de passo.

Além disso, nesse cenário de experimento controlado, foi possível estimar a constante de Lipschitz ( $L = 0.9996$ ). Sendo assim, decidiu-se por utilizar o melhor tamanho de passo fixo ( $\lambda = \frac{1}{L}$ ) que é de aproximadamente  $\lambda = 1$ .

Em todos os experimentos desse tipo de problema, utilizou-se a avaliação do valor da função objetivo  $f$  como critério de parada. Como operador de convolução  $A$ , foi adotado um kernel de média de dimensões  $7 \times 7$ . Em um experimento inicial, utilizou-se um limite máximo de 1000 iterações como critério de parada

e uma tolerância de  $1.0 \times 10^{-2}$ . Os resultados obtidos em termos de número de iterações, tempo para convergência e qualidade da reconstrução (PSNR) podem ser observados na Tabela 1 e nas Figuras 2 e 3.

Tabela 1: Convergência dos Métodos

| Método                     | Iterações | Tempo (segundos) | PSNR (dB) |
|----------------------------|-----------|------------------|-----------|
| Máxima Descida Passo Fixo  | 1000      | 41.64            | 30.4      |
| Máxima Descida Busca Exata | 849       | 58.73            | 31.23     |
| Nesterov Passo Fixo        | 109       | 4.8              | 31.25     |
| Nesterov Busca Exata       | 94        | 6.51             | 31.25     |
| Nesterov Backtracking      | 99        | 6.85             | 31.24     |
| Gradientes Conjugados      | 59        | 4.85             | 31.37     |

Menores valores de iterações e tempo indicam melhor desempenho computacional.

**Observação 2.** A métrica PSNR (*Peak Signal-to-Noise Ratio*) é amplamente utilizada para avaliar a qualidade de reconstrução de imagens, sendo que valores mais elevados indicam menor distorção em relação a imagem de referência.






Figura 2: Gráfico de convergência pelo número de iterações

Curvas mais baixas e que atingem valores reduzidos em menos iterações indicam melhor desempenho do método.




Figura 3: Gráfico de convergência pelo tempo de execução

Curvas mais baixas e que atingem valores reduzidos em menor tempo indicam melhor desempenho do método.

**Observação 3.** *É importante citar que o tamanho de passo  $\lambda = 1.2$  foi o utilizado na implementação do Nesterov com backtracking. Além disso, veja que é improvável que esse método apresente desempenho superior do que o passo fixo na nossa situação de simulação, já que estamos utilizando o tamanho de passo ótimo  $\lambda = \frac{1}{L}$  para o Nesterov com passo fixo.*

Esse primeiro experimento evidencia que em termos de iterações, a ordem dos métodos mais eficientes é: gradientes conjugados, Nesterov com busca linear exata, Nesterov com *backtracking*, Nesterov com passo fixo e máxima descida com busca exata. O método de máxima descida com passo fixo atingiu o limite máximo de iterações sem satisfazer o critério de convergência. Embora isso mostre que o uso da busca linear exata para definir o tamanho de passo reduza o número de iterações para atingir a convergência, ainda resta avaliar se o tempo computacional é reduzido. Quando se trata do método de Nesterov, as figuras nos apresentam que ao utilizar a busca exata, de fato há um ganho de performance tanto em números de iterações quanto na redução do tempo para convergir em relação ao método que utiliza *backtracking*. Isso é importante pois, por mais que ambos percam para o Nesterov com passo fixo ao utilizar o tamanho de passo ótimo

( $\lambda = \frac{1}{L}$ ), em aplicações reais é custoso computacionalmente estimar a constante de Lipschitz. No entanto, nesse caso onde a função objetivo é uma quadrática, há a possibilidade de utilizar o método dos gradientes conjugados, que nesses experimentos performou melhor que todos os outros algoritmos. Portanto, a ordem de eficiência por tempo computacional é dada por: Nesterov passo fixo, gradientes conjugados, Nesterov com busca exata, Nesterov com *backtracking* e máxima descida com busca exata. Nesse teste o método de máxima descida com passo fixo atingiu o número de iterações máxima sem alcançar a tolerância desejada. Quanto à qualidade da imagem recuperada, os valores de PSNR na Tabela 1 corroboram a superioridade dos métodos acelerados. Enquanto a Máxima Descida com passo fixo resultou no menor PSNR (30.4 dB) por não atingir a convergência plena, os métodos de Nesterov e Gradientes Conjugados estabilizaram em patamares superiores.

Vale destacar que o método de Gradientes Conjugados, além da eficiência em iterações, apresentou o maior PSNR (31.37 dB), evidenciando que a eficiência computacional foi acompanhada de uma reconstrução mais fiel. Observa-se também que as diferentes estratégias para o método de Nesterov atingiram valores de PSNR praticamente idênticos (aproximadamente 31.25 dB), o que indica que, embora o tipo de busca linear altere a velocidade de convergência, o algoritmo consistentemente converge para a mesma vizinhança do ponto ótimo. Outro experimento efetuado foi utilizando um limite de 200 iterações e uma tolerância de  $1.0 \times 10^{-5}$ . Com isso, chegamos nos resultados da Tabela 2.

Tabela 2: Comparação por Iteração

| Método                     | Iterações | Tempo (segundos) |
|----------------------------|-----------|------------------|
| Máxima Descida Passo Fixo  | 200       | 8.08             |
| Máxima Descida Busca Exata | 200       | 13.44            |
| Nesterov Passo Fixo        | 200       | 8.11             |
| Nesterov Busca Exata       | 200       | 13.35            |
| Nesterov Backtracking      | 200       | 13.63            |
| Gradientes Conjugados      | 200       | 16.02            |

Aqui não necessariamente quanto menor o tempo melhor, temos que avaliar a qualidade da reconstrução

Neste experimento, a análise prioriza a qualidade da reconstrução obtida por cada método, avaliada por meio da métrica PSNR, conforme ilustrado na Figura 4,

que evidencia a superioridade do método dos gradientes conjugados.




Figura 4: Qualidade da Reconstrução

Além desses experimentos, foram feitos alguns comparando o uso de busca exata com o backtracking no método de Nesterov. Rodando os métodos por 200 iterações, temos que o algoritmo que utiliza busca exata atinge o limite de iterações em 13.51 segundos, já utilizando *backtracking* leva 13.58 segundos. Na reconstrução vista na Figura 5, fica claro que o uso da busca exata traz vantagens tanto em tempo de convergência como na qualidade da imagem reconstruída em relação ao uso de *backtracking*



Figura 5: Qualidade da Reconstrução

Por último, comparou-se o método dos gradientes conjugados com o método de Nesterov utilizando busca linear exata. O experimento se deu considerando uma tolerância de  $1.0 \times 10^{-5}$  e um limite máximo de 1500 iterações. Os resultados podem ser vistos na Tabela 3 em conjunto com a qualidade da reconstrução na Figura 6. Neste cenário, o Gradiente Conjugado mostrou-se superior ao atingir a convergência em 61.89 segundos, contra 88.78 segundos do Nesterov. É importante ressaltar que a diferença de PSNR (40.27 do GC contra 40.60 do Nesterov) é marginal, tornando o Gradiente Conjugado a escolha mais eficiente para o problema quadrático em questão.

Tabela 3: Comparação Nesterov Busca Exata e Gradientes Conjugados

| Método               | Iterações | Tempo (segundos) |
|----------------------|-----------|------------------|
| Nesterov Busca Exata | 1317      | 88.44            |
| Gradiente Conjugado  | 755       | 61.34            |

Menores valores de iterações e tempo indicam melhor desempenho computacional.




Figura 6: Qualidade da Reconstrução

### 3.2 Métodos com Regularização para Reconstrução de Imagens

Em um primeiro momento, consideramos o problema composto:

$$\min F(x) = \frac{1}{2} \|Ax - b\|_2^2 + \gamma \|Hx\|_1$$

onde  $A$  é um operador de convolução,  $x$  é a imagem a ser recuperada,  $b$  é a imagem borrada e ruidosa e  $H$  é uma transformada *wavelet*. Para a geração de  $b$ , foi utilizada a imagem *astronaut* da biblioteca *scikit-image* e foram utilizados um operador de convolução com um kernel de média de dimensões  $7 \times 7$  e um ruído gaussiano com média  $\mu = 0$  e desvio padrão  $\sigma = 0.01$  (para reprodutibilidade foi adotada a *seed* = 0). Para o termo de regularização foi utilizada a *wavelet* de Daubechies. Além disso, foi possível estimar a constante de Lipschitz  $L_f = 0.9997$ , permitindo assim garantir o limite de convergência teórico para o ISTA ( $\lambda < \frac{2}{L_f} = 2.0006$ ) e para o FISTA ( $\lambda \leq \frac{1}{L_f} = 1.0003$ ). Portanto, o tamanho de passo  $\lambda = 1$  foi utilizado para os algoritmos de passo fixo e *backtracking*. Nesta seção utilizamos a norma  $\|x_k - x_{k-1}\|_F$  como critério de parada.

O parâmetro de regularização  $\gamma$  foi determinado de maneira empírica, através de um grid search que seleciona o valor que minimiza o erro quadrático em relação a imagem original. Os testes feitos podem ser observados na Figura 7




Figura 7: Análise do erro para diferentes valores do parâmetro de regularização  $\gamma$ .

Dessa maneira, em um primeiro experimento optou-se pela utilização de  $\gamma = 0.001$ , um limite de 250 iterações e uma tolerância de  $1.0 \times 10^{-2}$ . Os resultados podem ser observados nas Figuras 8 e 9.




Figura 8: Gráfico da diferença entre  $F(x_k) - F(x^*)$

Curvas que atingem valores reduzidos em menos iterações e menor tempo indicam melhor desempenho do método. O valor  $F(x^*)$  foi definido como o valor mínimo numérico entre todos os algoritmos




Figura 9: Gráfico da diferença entre  $F(x_k) - F(x_{k-1})$

Decaimentos estáveis indicam maior estabilidade e que o algoritmo está convergindo de forma consistente para o mínimo. Note que o FISTA Backtracking está sobreposto ao FISTA Fixo.

A análise das imagens nos revela que o uso da busca exata, tanto no ISTA quanto no FISTA, compromete a convergência e a estabilidade dos algoritmos. Enquanto as implementações que utilizam passo fixo ou *backtracking* respeitam os critérios de convergência, a busca exata, por ser calculada com base apenas no termo quadrático, negligencia o termo não diferenciável. Isso resulta em passos que não satisfazem a condição de descida para a função compósita, gerando a instabilidade observada.

Para investigar tal comportamento, podemos ver na Figura 10 que os tamanhos de passo gerados pelos algoritmos não respeitam o limite teórico de convergência, impedindo que os métodos alcancem o mínimo.






Figura 10: Tamanho de passo

Note a instabilidade e a quebra do limite teórico de convergência.

Para investigar a sensibilidade dos métodos ao termo de regularização, realizaram-se testes com diferentes valores de  $\gamma$  (em específico os valores foram  $\gamma \in \{0.0001, 0.001, 0.01, 0.1, 0.2\}$ ), limite de 250 iterações e uma tolerância de  $1.0 \times 10^{-2}$ . Esses testes justificam-se pelo fato de o passo exato ser calculado com base apenas na parcela suave da função a ser minimizada, tornando-se teoricamente mais adequado ao problema conforme a importância do termo não suave diminui. Os resultados podem ser observados nas Figuras 11 e 12.




Figura 11: Gráficos comparativos de  $F(x_k) - F(x^*)$  para diferentes valores de  $\gamma$




Figura 12: Gráficos comparativos de  $F(x_k) - F(x_{k-1})$  para diferentes valores de  $\gamma$

Na Tabela 4 pode ser visto um resumo do comportamento dos métodos com passo exato para os diferentes valores de  $\gamma$ .

Tabela 4: Comparação para diferentes valores de  $\gamma$ 

| Gamma       | FISTA Exato                 | ISTA Exato                       |
|-------------|-----------------------------|----------------------------------|
| 0.0001      | Convergência com oscilações | Convergência lenta e oscilatória |
| 0.001; 0.01 | Oscilações sem convergência | Oscilações sem convergência      |
| $\geq 0.1$  | Oscilações sem convergência | Convergência estável             |

Para pequenos valores de  $\gamma$  (quando  $\gamma \rightarrow 0$ ), temos que a função objetivo se aproxima do problema puramente quadrático, onde vimos na seção anterior que os algoritmos funcionam bem nesse caso.

Para valores elevados de  $\gamma$ , o operador de soft-thresholding impõe uma forte esparsidade à solução, limitando a magnitude dos iterados. No ISTA, esse efeito favorece a estabilidade. Como cada iteração  $x_k$  depende exclusivamente de  $x_{k-1}$ , o soft-thresholding atua como um amortecedor, mantendo os iterados próximos, como visto na Figura 13 e, conseqüentemente, o gradiente de  $f$  varia pouco, já que este é Lipschitz contínuo. Com gradientes semelhantes, a busca linear exata produz tamanhos de passo  $\lambda_k$  que se estabilizam, permitindo a convergência observada na Figura 14. Já no FISTA, a instabilidade persiste devido ao termo de *momentum*. A extrapolação  $y_k = x_k + \beta_k(x_k - x_{k-1})$  amplifica pequenas diferenças entre iterados. O gradiente  $\nabla f(y_k)$  pode diferir significativamente entre iterações, levando a passos  $\lambda_k$  distintos e reverberando oscilações que o soft-thresholding não consegue suprimir. Esse comportamento é evidenciado nas Figuras 13 e 14, onde as curvas do FISTA não apresentam a estabilização observada no ISTA.

Para os valores intermediários, que são os de grande interesse já que resultam nas melhores reconstruções das imagens (ver Tabela 5), o operador de *soft thresholding* não consegue amortecer as oscilações da busca exata. Sendo assim, tanto o ISTA quanto o FISTA apresentam instabilidades.

Tabela 5: PSNR para diferentes valores de  $\gamma$

| Gamma  | PSNR     |
|--------|----------|
| 0.0001 | 27.0 dB  |
| 0.001  | 27.87 dB |
| 0.01   | 25.64 dB |
| 0.1    | 23.26 dB |
| 0.2    | 22.09 dB |

Aqui foi considerado as reconstruções do FISTA com *backtracking*




Figura 13: Gráfico da diferença  $\|x_k - x_{k-1}\|_F$  para  $\gamma = 0.1$




Figura 14: Tamanho de passo para  $\gamma = 0.1$

## 4 Conclusão

Neste trabalho, investigamos a influência do uso da busca linear exata para a reconstrução de imagens em algoritmos acelerados de primeira ordem. No cenário de *deblurring* sem regularização, os experimentos demonstram que o método dos gradientes conjugados apresenta o melhor compromisso entre custo computacional e qualidade da reconstrução, superando o método de Nesterov mesmo quando este utiliza a busca linear exata. Observou-se que a busca exata, em comparação ao critério de descida suficiente com *backtracking* reduziu tanto o número de iterações quanto o tempo computacional para o método de Nesterov, embora este ainda se mostre menos eficiente que os gradientes conjugados no caso puramente quadrático. Uma etapa subsequente do projeto focará em tentar otimizar a busca exata para o método de Nesterov. Nesse sentido, pretende-se reaproveitar cálculos de produto do tipo  $Qd_k$  (ver Proposição 3), visando reduzir o tempo de execução por iteração e tornar o método mais competitivo frente aos gradientes conjugados.

No cenário com regularização  $L_1$  (*wavelets*), a busca exata demonstrou-se inadequada. Por ignorar a parcela não suave da função objetivo, o algoritmo frequentemente viola os limites teóricos de convergência, levando a instabilidades. A comparação entre o ISTA e o FISTA revelou que o termo de *momentum* amplifica essa instabilidade. No ISTA, a forte esparsidade promovida ao utilizar  $\gamma \geq 0.1$  consegue amortecer as oscilações, fenômeno que não ocorre no FISTA, onde o erro é amplificado ao longo das iterações, impedindo a convergência do método.

As próximas etapas deste trabalho consistem em explorar o uso do passo exato quando o termo regularizador é a variação total (TV) e aplicar esses algoritmos para a reconstrução de imagens de tomografia computadorizada (TC).

## Referências

- [1] Amir Beck e Marc Teboulle. “A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems”. Em: *SIAM Journal on Imaging Sciences* 2.1 (2009), pp. 183–202. DOI: 10.1137/080716542. eprint: <https://doi.org/10.1137/080716542>. URL: <https://doi.org/10.1137/080716542>.
- [2] Amir Beck e Marc Teboulle. “Fast Gradient-Based Algorithms for Constrained Total Variation Image Denoising and Deblurring Problems”. Em: *IEEE Transactions on Image Processing* 18.11 (2009), pp. 2419–2434. DOI: 10.1109/TIP.2009.2028250.