

UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE
COMPUTAÇÃO

DEPARTAMENTO DE MATEMÁTICA APLICADA E ESTATÍSTICA

RELATÓRIO CIENTÍFICO SEMESTRAL

**Influência do Uso de Busca Linear Exata na
Convergência de Métodos Acelerados de Gradiente
Proximal**

LINHA DE FOMENTO: BOLSA NO PAÍS - REGULAR - INICIAÇÃO CIENTÍFICA

Processo FAPESP: 2025/12023-2

Período de vigência: 01/09/2025 a 31/08/2026

Bolsista:
Gabriel Ligabô Baba

Orientador:
Elias Salomão Helou Neto

São Carlos – SP
19 de fevereiro de 2026

Sumário

1	Introdução	2
2	Fundamentação Matemática	2
2.1	ISTA e FISTA	4
3	Resultados	5
3.1	Métodos sem Regularização para <i>Deblurring</i> de Imagens	5
3.2	Métodos com Regularização para Reconstrução de Imagens	12
4	Conclusão	20

1 Introdução

Métodos de otimização são peça-chave em reconstrução de imagens médicas, especialmente em tomografia computadorizada. Os dados adquiridos por esta técnica consistem em uma amostragem ruidosa da transformada de Radon, o que leva à necessidade da adição de termos de regularização ao modelo de otimização, para que assim o ruído contido nos dados não seja excessivamente amplificado na imagem reconstruída. Muitas das possíveis escolhas para o termo regularizador não são suaves, mas são convexas e prox-amigáveis, levando ao uso de algoritmos de otimização do tipo gradiente proximal acelerado. Este projeto aborda um ponto específico e pouco explorado: propomos substituir as estratégias de tamanho de passo usuais (e.g., passo fixo ou determinado por busca inexata com critério de descida suficiente) no algoritmo FISTA (Fast Iterative Shrinkage-Thresholding Algorithm). Em seu lugar, investigar-se-á o uso de uma busca linear exata para determinar o tamanho de passo. Especificamente, usaremos um termo de quadrados mínimos na parcela de consistência e calcularemos analiticamente o passo que minimiza tal parcela ao longo da direção de máxima descida. A meta é medir, de forma objetiva, como tal escolha afeta a convergência em iterações e o tempo de computação, além da qualidade de reconstrução em dados de tomografia computadorizada.

2 Fundamentação Matemática

Definição 1. Um subconjunto $X \subset \mathbb{R}^n$ é dito convexo se, para todo $x, y \in X$ e $\lambda \in [0, 1]$, ele satisfaz que:

$$\lambda x + (1 - \lambda)y$$

também pertence a X .

Definição 2. Seja $X \subset \mathbb{R}^n$. Seja $f : X \rightarrow \mathbb{R}$, f é dita convexa se, para quaisquer $x, y \in X$ e $\lambda \in [0, 1]$ temos:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

As funções convexas nos dão algumas propriedades fundamentais, como as seguintes:

Proposição 1. Seja f uma função de classe C^1 . Então f é convexa em X , se e somente se, para todo $x, y \in X$

$$f(y) \geq f(x) + \nabla f(x)^T(y - x)$$

Em outras palavras, isso significa que a aproximação de primeira ordem de Taylor sempre subestima o valor real da função.

Proposição 2. *Seja f uma função de classe C^2 . Seja $X \subset \mathbb{R}^n$, então f é convexa se e somente se, para todo $x \in X$:*

$$\nabla^2 f(x) \geq 0$$

Definição 3. *Dizemos que um vetor $g \in \mathbb{R}^n$, onde X é convexo, é um subgradiente de $f : X \rightarrow \mathbb{R}$ convexa em um ponto $x \in X$ se, para todo $y \in X$ a seguinte desigualdade for satisfeita:*

$$f(y) \geq f(x) + g^T(y - x)$$

Em outras palavras, g define um hiperplano de suporte para o epígrafo de f no ponto $(x, f(x))$. Se f for diferenciável, então o subgradiente é o próprio gradiente da função.

Observação 1. *O epígrafo de uma função é definido como $\text{epi}(f) = \{(x, y) : x \in \mathbb{R}^n, y \in \mathbb{R}, f(x) \leq y\}$*

Definição 4. *O conjunto de todos os subgradientes em um ponto $x \in X$ é chamado de subdiferencial de f em x . A notação usada é:*

$$\partial f(x) = \{g \in \mathbb{R}^n : g^T(y - x) \leq f(y) - f(x), \forall y \in X\}$$

Definição 5. *Seja $f : X \rightarrow \mathbb{R}$ uma função convexa. Definimos o operador proximal como sendo:*

$$\text{prox}_f(v) = \arg \min_{x \in X} \{f(x) + \frac{1}{2} \|x - v\|_2^2\}$$

A função f também pode ser multiplicada por uma constante $\lambda > 0$. Então o operador proximal fica:

$$\text{prox}_{\lambda f}(v) = \arg \min_{x \in X} \{f(x) + \frac{1}{2\lambda} \|x - v\|_2^2\}$$

Definição 6. *Uma função f é dita L_f -suave se seu gradiente é Lipschitz contínuo com parâmetro L_f . Isto é:*

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L_f \|x - y\|_2$$

Proposição 3. No problema de mínimos quadrados definido por $f(x) = \frac{1}{2} \|Ax - b\|_2^2$, o tamanho de passo que minimiza a função ao longo da direção d_k é dado por:

$$\lambda_k = -\frac{\nabla f(x_k)^T d_k}{d_k^T Q d_k}$$

, onde $Q = A^T A$

2.1 ISTA e FISTA

Quando estamos lidando com o problema compósito:

$$\min F(x) = f(x) + \gamma g(x)$$

onde:

$f(x)$ é uma função suave e convexa

$g(x)$ é uma função convexa não suave.

Uma possível forma de resolvê-lo é utilizando um método chamado de ISTA (*Iterative Shrinkage-Thresholding Algorithm*). A ideia por trás deste método, é aproveitar da suavidade de f para realizar um passo da descida do gradiente e, em seguida, corrigir o efeito da parte não diferenciável via operador proximal. Então fazemos:

Algorithm 1 ISTA

- 1: **Entrada:** $x_0 \in \mathbb{R}^n$, passo $\lambda > 0$.
 - 2: **for** $k = 0, 1, 2, \dots$ **do**
 - 3: $x_{k+1} = \text{prox}_{\gamma\lambda g}(x_k - \lambda \nabla f(x_k))$
 - 4: **end for**
 - 5: **Retorno:** Solução aproximada x^* .
-

Uma variação mais eficiente é o FISTA (*Fast Iterative Shrinkage-Thresholding Algorithm*) [1], que utiliza o momento de Nesterov para acelerar a convergência.

Algorithm 2 FISTA

1: **Entrada:** $x_0 \in \mathbb{R}^n$, $\lambda > 0$.
2: **Inicialização:** $y_1 = x_0$, $t_1 = 1$.
3: **for** $k = 1, 2, \dots$ **do**
4: $x_k = \text{prox}_{\gamma\lambda g}(y_k - \lambda \nabla f(y_k))$
5: $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$
6: $y_{k+1} = x_k + \left(\frac{t_k - 1}{t_{k+1}}\right)(x_k - x_{k-1})$
7: **end for**
8: **Retorno:** Solução aproximada x^* .

Um dos casos que será foco deste trabalho, é a utilização de $g(x) = \|Hx\|_1$, onde H é uma transformada *wavelet* ortonormal auto-adjunta. Neste caso, o operador proximal é facilmente computável, tendo fórmula fechada dada por:

$$\text{prox}_{\lambda\gamma g}(x) = H^T \mathcal{S}_{\lambda\gamma}(Hx)$$

onde $\mathcal{S}_{\lambda\gamma}$ é o operador de *soft-thresholding*.

Um outro caso de interesse é quando $g(x) = TV(x)$, onde $x \in \mathbb{R}^{m \times n}$:

$$TV(x) = \sum_{i=1}^{m-1} \sum_{j=1}^{n-1} \sqrt{(x_{i,j} - x_{i+1,j})^2 + (x_{i,j} - x_{i,j+1})^2} + \sum_{i=1}^{m-1} |x_{i,n} - x_{i+1,n}| + \sum_{j=1}^{n-1} |x_{m,j} - x_{m,j+1}|$$

Neste caso, não existe forma fechada para o cálculo do operador proximal, mas o algoritmo rápido apresentado em [2] será implementado na linguagem python.

3 Resultados

3.1 Métodos sem Regularização para *Deblurring* de Imagens

Nessa etapa do projeto, comparamos diversos métodos: máxima descida com passo fixo (MDPF), máxima descida com busca linear exata (MDBE), método de Nesterov com passo fixo, método de Nesterov com critério de descida suficiente (com *backtracking*), método de Nesterov com busca linear exata e gradientes conjugados para reconstrução de imagens borradas. O objetivo é:

$$\min_x \|Ax - b\|_2^2$$

onde A representa um operador de convolução (responsável pelo *blur*), x a imagem original a ser recuperada e b a imagem borrada.

Esses métodos foram comparados em termos de iterações e tempo de convergência visando analisar a influência do uso da busca linear exata. Implementamos todos os métodos em linguagem de programação Python com o uso de bibliotecas como Scipy, Numpy e Matplotlib. A imagem a ser recuperada foi a *coffee* da biblioteca *scikit-image*.

Inicialmente, foi utilizado um *grid search* para encontrar o melhor parâmetro de tamanho de passo, conforme apresentado na Figura 1:




Figura 1: Análise de tamanho de passo.

Além disso, nesse cenário de experimento controlado, foi possível estimar a constante de Lipschitz ($L = 0.9996$). Sendo assim, decidiu-se por utilizar o melhor tamanho de passo fixo ($\lambda = \frac{1}{L}$) que é de aproximadamente $\lambda = 1$.

Em todos os experimentos desse tipo de problema, utilizou-se a avaliação do valor da função objetivo f como critério de parada. Como operador de convolução A , foi adotado um kernel de média de dimensões 7×7 . Em um experimento inicial, utilizou-se um limite máximo de 1000 iterações como critério de parada e uma tolerância de 1.0×10^{-2} . Os resultados obtidos em termos de número de iterações, tempo para convergência e qualidade da reconstrução (PSNR) podem ser observados na Tabela 1 e nas Figuras 2 e 3.

Tabela 1: Convergência dos Métodos

Método	Iterações	Tempo (segundos)	PSNR (dB)
Máxima Descida Passo Fixo	1000	41.64	30.4
Máxima Descida Busca Exata	849	58.73	31.23
Nesterov Passo Fixo	109	4.8	31.25
Nesterov Busca Exata	94	6.51	31.25
Nesterov Backtracking	99	6.85	31.24
Gradientes Conjugados	59	4.85	31.37

Menores valores de iterações e tempo indicam melhor desempenho computacional.

Observação 2. A métrica PSNR (*Peak Signal-to-Noise Ratio*) é amplamente utilizada para avaliar a qualidade de reconstrução de imagens, sendo que valores mais elevados indicam menor distorção em relação a imagem de referência.




Figura 2: Gráfico de convergência pelo número de iterações

Curvas mais baixas e que atingem valores reduzidos em menos iterações indicam melhor desempenho do método.




Figura 3: Gráfico de convergência pelo tempo de execução

Curvas mais baixas e que atingem valores reduzidos em menor tempo indicam melhor desempenho do método.

Observação 3. *É importante citar que o tamanho de passo $\lambda = 1.2$ foi o utilizado na implementação do Nesterov com backtracking. Além disso, veja que é improvável que esse método apresente desempenho superior do que o passo fixo na nossa situação de simulação, já que estamos utilizando o tamanho de passo ótimo $\lambda = \frac{1}{L}$ para o Nesterov com passo fixo.*

Esse primeiro experimento evidencia que em termos de iterações, a ordem dos métodos mais eficientes é: gradientes conjugados, Nesterov com busca linear exata, Nesterov com *backtracking*, Nesterov com passo fixo e máxima descida com busca exata. O método de máxima descida com passo fixo atingiu o limite máximo de iterações sem satisfazer o critério de convergência. Embora isso mostre que o uso da busca linear exata para definir o tamanho de passo reduza o número de iterações para atingir a convergência, ainda resta avaliar se o tempo computacional é reduzido. Quando se trata do método de Nesterov, as figuras nos apresentam que ao utilizar a busca exata, de fato há um ganho de performance tanto em números de iterações quanto na redução do tempo para convergir em relação ao método que utiliza *backtracking*. Isso é importante pois, por mais que ambos percam para o Nesterov com passo fixo ao utilizar o tamanho de passo ótimo

($\lambda = \frac{1}{L}$), em aplicações reais é custoso computacionalmente estimar a constante de Lipschitz. No entanto, nesse caso onde a função objetivo é uma quadrática, há a possibilidade de utilizar o método dos gradientes conjugados, que nesses experimentos performou melhor que todos os outros algoritmos. Portanto, a ordem de eficiência por tempo computacional é dada por: Nesterov passo fixo, gradientes conjugados, Nesterov com busca exata, Nesterov com *backtracking* e máxima descida com busca exata. Nesse teste o método de máxima descida com passo fixo atingiu o número de iterações máxima sem alcançar a tolerância desejada. Quanto à qualidade da imagem recuperada, os valores de PSNR na Tabela 1 corroboram a superioridade dos métodos acelerados. Enquanto a Máxima Descida com passo fixo resultou no menor PSNR (30.4 dB) por não atingir a convergência plena, os métodos de Nesterov e Gradientes Conjugados estabilizaram em patamares superiores.

Vale destacar que o método de Gradientes Conjugados, além da eficiência em iterações, apresentou o maior PSNR (31.37 dB), evidenciando que a eficiência computacional foi acompanhada de uma reconstrução mais fiel. Observa-se também que as diferentes estratégias para o método de Nesterov atingiram valores de PSNR praticamente idênticos (aproximadamente 31.25 dB), o que indica que, embora o tipo de busca linear altere a velocidade de convergência, o algoritmo consistentemente converge para a mesma vizinhança do ponto ótimo. Outro experimento efetuado foi utilizando um limite de 200 iterações e uma tolerância de 1.0×10^{-5} . Com isso, chegamos nos resultados da Tabela 2.

Tabela 2: Comparação por Iteração

Método	Iterações	Tempo (segundos)
Máxima Descida Passo Fixo	200	8.08
Máxima Descida Busca Exata	200	13.44
Nesterov Passo Fixo	200	8.11
Nesterov Busca Exata	200	13.35
Nesterov Backtracking	200	13.63
Gradientes Conjugados	200	16.02

Aqui não necessariamente quanto menor o tempo melhor, temos que avaliar a qualidade da reconstrução

Neste experimento, a análise prioriza a qualidade da reconstrução obtida por cada método, avaliada por meio da métrica PSNR, conforme ilustrado na Figura 4,

que evidencia a superioridade do método dos gradientes conjugados.




Figura 4: Qualidade da Reconstrução

Além desses experimentos, foram feitos alguns comparando o uso de busca exata com o backtracking no método de Nesterov. Rodando os métodos por 200 iterações, temos que o algoritmo que utiliza busca exata atinge o limite de iterações em 13.51 segundos, já utilizando *backtracking* leva 13.58 segundos. Na reconstrução vista na Figura 5, fica claro que o uso da busca exata traz vantagens tanto em tempo de convergência como na qualidade da imagem reconstruída em relação ao uso de *backtracking*



Figura 5: Qualidade da Reconstrução

Por último, comparou-se o método dos gradientes conjugados com o método de Nesterov utilizando busca linear exata. O experimento se deu considerando uma tolerância de 1.0×10^{-5} e um limite máximo de 1500 iterações. Os resultados podem ser vistos na Tabela 3 em conjunto com a qualidade da reconstrução na Figura 6. Neste cenário, o Gradiente Conjugado mostrou-se superior ao atingir a convergência em 61.89 segundos, contra 88.78 segundos do Nesterov. É importante ressaltar que a diferença de PSNR (40.27 do GC contra 40.60 do Nesterov) é marginal, tornando o Gradiente Conjugado a escolha mais eficiente para o problema quadrático em questão.

Tabela 3: Comparação Nesterov Busca Exata e Gradientes Conjugados

Método	Iterações	Tempo (segundos)
Nesterov Busca Exata	1317	88.44
Gradiente Conjugado	755	61.34

Menores valores de iterações e tempo indicam melhor desempenho computacional.



Figura 6: Qualidade da Reconstrução

3.2 Métodos com Regularização para Reconstrução de Imagens

Em um primeiro momento, consideramos o problema compósito:

$$\min F(x) = \frac{1}{2} \|Ax - b\|_2^2 + \gamma \|Hx\|_1$$

onde A é um operador de convolução, x é a imagem a ser recuperada, b é a imagem borrada e ruidosa e H é uma transformada *wavelet*. Para a geração de b , foi utilizada a imagem *astronaut* da biblioteca *scikit-image* e foram utilizados um operador de convolução com um kernel de média de dimensões 7×7 e um ruído gaussiano com média $\mu = 0$ e desvio padrão $\sigma = 0.01$ (para reprodutibilidade foi adotada a *seed* = 0). Para o termo de regularização foi utilizada a *wavelet* de Daubechies. Além disso, foi possível estimar a constante de Lipschitz $L_f = 0.9997$, permitindo assim garantir o limite de convergência teórico para o ISTA ($\lambda < \frac{2}{L_f} = 2.0006$) e para o FISTA ($\lambda \leq \frac{1}{L_f} = 1.0003$). Portanto, o tamanho de passo $\lambda = 1$ foi utilizado para os algoritmos de passo fixo e *backtracking*. Nesta seção utilizamos a norma $\|x_k - x_{k-1}\|_F$ como critério de parada.

O parâmetro de regularização γ foi determinado de maneira empírica, através de um grid search que seleciona o valor que minimiza o erro quadrático em relação a imagem original. Os testes feitos podem ser observados na Figura 7




Figura 7: Análise do erro para diferentes valores do parâmetro de regularização γ .

Dessa maneira, em um primeiro experimento optou-se pela utilização de $\gamma = 0.001$, um limite de 250 iterações e uma tolerância de 1.0×10^{-2} . Os resultados podem ser observados nas Figuras 8 e 9.




Figura 8: Gráfico da diferença entre $F(x_k) - F(x^*)$

Curvas que atingem valores reduzidos em menos iterações e menor tempo indicam melhor desempenho do método. O valor $F(x^*)$ foi definido como o valor mínimo numérico entre todos os algoritmos




Figura 9: Gráfico da diferença entre $F(x_k) - F(x_{k-1})$

Decaimentos estáveis indicam maior estabilidade e que o algoritmo está convergindo de forma consistente para o mínimo. Note que o FISTA Backtracking está sobreposto ao FISTA Fixo.

A análise das imagens nos revela que o uso da busca exata, tanto no ISTA quanto no FISTA, compromete a convergência e a estabilidade dos algoritmos. Enquanto as implementações que utilizam passo fixo ou *backtracking* respeitam os critérios de convergência, a busca exata, por ser calculada com base apenas no termo quadrático, negligencia o termo não diferenciável. Isso resulta em passos que não satisfazem a condição de descida para a função compósita, gerando a instabilidade observada.

Para investigar tal comportamento, podemos ver na Figura 10 que os tamanhos de passo gerados pelos algoritmos não respeitam o limite teórico de convergência, impedindo que os métodos alcancem o mínimo.




Figura 10: Tamanho de passo

Note a instabilidade e a quebra do limite teórico de convergência.

Para investigar a sensibilidade dos métodos ao termo de regularização, realizaram-se testes com diferentes valores de γ (em específico os valores foram $\gamma \in \{0.0001, 0.001, 0.01, 0.1, 0.2\}$), limite de 250 iterações e uma tolerância de 1.0×10^{-2} . Esses testes justificam-se pelo fato de o passo exato ser calculado com base apenas na parcela suave da função a ser minimizada, tornando-se teoricamente mais adequado ao problema conforme a importância do termo não suave diminui. Os resultados podem ser observados nas Figuras 11 e 12.




Figura 11: Gráficos comparativos de $F(x_k) - F(x^*)$ para diferentes valores de γ




Figura 12: Gráficos comparativos de $F(x_k) - F(x_{k-1})$ para diferentes valores de γ

Na Tabela 4 pode ser visto um resumo do comportamento dos métodos com passo exato para os diferentes valores de γ .

Tabela 4: Comparação para diferentes valores de γ

Gamma	FISTA Exato	ISTA Exato
0.0001	Convergência com oscilações	Convergência lenta e oscilatória
0.001; 0.01	Oscilações sem convergência	Oscilações sem convergência
≥ 0.1	Oscilações sem convergência	Convergência estável

Para pequenos valores de γ (quando $\gamma \rightarrow 0$), temos que a função objetivo se aproxima do problema puramente quadrático, onde vimos na seção anterior que os algoritmos funcionam bem nesse caso.

Para valores elevados de γ , o operador de soft-thresholding impõe uma forte esparsidade à solução, limitando a magnitude dos iterados. No ISTA, esse efeito favorece a estabilidade. Como cada iteração x_k depende exclusivamente de x_{k-1} , o soft-thresholding atua como um amortecedor, mantendo os iterados próximos, como visto na Figura 13 e, conseqüentemente, o gradiente de f varia pouco, já que este é Lipschitz contínuo. Com gradientes semelhantes, a busca linear exata produz tamanhos de passo λ_k que se estabilizam, permitindo a convergência observada na Figura 14. Já no FISTA, a instabilidade persiste devido ao termo de *momentum*. A extrapolação $y_k = x_k + \beta_k(x_k - x_{k-1})$ amplifica pequenas diferenças entre iterados. O gradiente $\nabla f(y_k)$ pode diferir significativamente entre iterações, levando a passos λ_k distintos e reverberando oscilações que o soft-thresholding não consegue suprimir. Esse comportamento é evidenciado nas Figuras 13 e 14, onde as curvas do FISTA não apresentam a estabilização observada no ISTA.

Para os valores intermediários, que são os de grande interesse já que resultam nas melhores reconstruções das imagens (ver Tabela 5), o operador de *soft thresholding* não consegue amortecer as oscilações da busca exata. Sendo assim, tanto o ISTA quanto o FISTA apresentam instabilidades.

Tabela 5: PSNR para diferentes valores de γ

Gamma	PSNR
0.0001	27.0 dB
0.001	27.87 dB
0.01	25.64 dB
0.1	23.26 dB
0.2	22.09 dB

Aqui foi considerado as reconstruções do FISTA com *backtracking*




Figura 13: Gráfico da diferença $\|x_k - x_{k-1}\|_F$ para $\gamma = 0.1$




Figura 14: Tamanho de passo para $\gamma = 0.1$

4 Conclusão

Neste trabalho, investigamos a influência do uso da busca linear exata para a reconstrução de imagens em algoritmos acelerados de primeira ordem. No cenário de *deblurring* sem regularização, os experimentos demonstram que o método dos gradientes conjugados apresenta o melhor compromisso entre custo computacional e qualidade da reconstrução, superando o método de Nesterov mesmo quando este utiliza a busca linear exata. Observou-se que a busca exata, em comparação ao critério de descida suficiente com *backtracking* reduziu tanto o número de iterações quanto o tempo computacional para o método de Nesterov, embora este ainda se mostre menos eficiente que os gradientes conjugados no caso puramente quadrático. Uma etapa subsequente do projeto focará em tentar otimizar a busca exata para o método de Nesterov. Nesse sentido, pretende-se reaproveitar cálculos de produto do tipo Qd_k (ver Proposição 3), visando reduzir o tempo de execução por iteração e tornar o método mais competitivo frente aos gradientes conjugados.

No cenário com regularização L_1 (*wavelets*), a busca exata demonstrou-se inadequada. Por ignorar a parcela não suave da função objetivo, o algoritmo frequentemente viola os limites teóricos de convergência, levando a instabilidades. A comparação entre o ISTA e o FISTA revelou que o termo de *momentum* amplifica essa instabilidade. No ISTA, a forte esparsidade promovida ao utilizar $\gamma \geq 0.1$ consegue amortecer as oscilações, fenômeno que não ocorre no FISTA, onde o erro é amplificado ao longo das iterações, impedindo a convergência do método.

As próximas etapas deste trabalho consistem em explorar o uso do passo exato quando o termo regularizador é a variação total (TV) e aplicar esses algoritmos para a reconstrução de imagens de tomografia computadorizada (TC).

Referências

- [1] Amir Beck e Marc Teboulle. “A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems”. Em: *SIAM Journal on Imaging Sciences* 2.1 (2009), pp. 183–202. DOI: 10.1137/080716542. eprint: <https://doi.org/10.1137/080716542>. URL: <https://doi.org/10.1137/080716542>.
- [2] Amir Beck e Marc Teboulle. “Fast Gradient-Based Algorithms for Constrained Total Variation Image Denoising and Deblurring Problems”. Em: *IEEE Transactions on Image Processing* 18.11 (2009), pp. 2419–2434. DOI: 10.1109/TIP.2009.2028250.