

UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO

DEPARTAMENTO DE MATEMÁTICA APLICADA E ESTATÍSTICA

RELATÓRIO CIENTÍFICO FINAL

**Influência do Uso de Busca Linear Exata na Convergência de
Métodos Acelerados de Gradiente Proximal**

LINHA DE FOMENTO: BOLSA NO PAÍS - REGULAR - INICIAÇÃO CIENTÍFICA

Processo FAPESP: 2025/12023-2

Período de vigência: 01/09/2025 a 31/08/2026

Bolsista:

Gabriel Ligabô Baba

Orientador:

Elias Salomão Helou Neto

São Carlos – SP

Agosto de 2026

Sumário

1	Introdução	3
1.1	ISTA e FISTA	3
2	Metodologia	5
2.1	Problemas sem Regularização	5
2.2	Problemas com Regularização	6
2.3	Estimativa da Constante de Lipschitz	6
2.4	Otimização Computacional da Busca Linear Exata	6
3	Resultados	7
3.1	Problemas Quadráticos (Sem Regularização)	7
3.1.1	Deblurring de Imagens	7
3.1.2	Tomografia Computadorizada	9
3.2	Problemas Regularizados	10
3.2.1	Regularização no Domínio <i>Wavelet</i> (ℓ_1)	10
3.2.2	Regularização por Variação Total (TV)	13
3.2.3	Comparação de Reconstrução: Variação Total vs. <i>Wavelets</i>	16
4	Conclusão	16
A	Fundamentação Teórica e Definições Básicas	19
B	Gráficos dos Algoritmos	21
B.1	Métodos sem Regularização	21
B.2	Métodos com Regularização (<i>Wavelets</i> e TV em Imagens)	25
B.3	Gráficos - Tomografia Computadorizada (Sem Regularização)	33
B.4	Gráficos - Tomografia Computadorizada (<i>Wavelets</i> e Variação Total)	40

Resumo

Neste trabalho investigou-se o impacto da busca linear exata em métodos de otimização suave e de gradiente proximal (ISTA/FISTA) para reconstrução de imagens. Em problemas quadráticos, a busca exata acelera a convergência de métodos como o Nesterov, mas em problemas regularizados com termos não suaves (norma ℓ_1 no domínio *wavelet* e regularização por variação total) os passos calculados ignoram a geometria do termo de regularização, causando instabilidade assintótica. Observou-se, porém, um fenômeno consistente de semi-convergência, onde o FISTA com o passo

exato atinge rapidamente uma alta qualidade de reconstrução. Os resultados sugerem que estratégias híbridas de otimização podem ser promissoras.

1 Introdução

A reconstrução de imagens em tomografia computadorizada (TC) configura um problema inverso tipicamente mal condicionado. Para obter soluções estáveis e mitigar os ruídos inerentes à amostragem da transformada de Radon, o problema é formulado matematicamente com a adição de termos de regularização convexos, porém frequentemente não diferenciáveis, como a variação total (TV) ou a norma ℓ_1 no domínio *wavelet*. Essa característica exige o emprego de algoritmos de gradiente proximal, destacando-se o FISTA (*Fast Iterative Shrinkage-Thresholding Algorithm*) por sua aceleração via *momentum* de Nesterov.

A eficiência de tais métodos de primeira ordem é dependente da escolha do tamanho de passo. Abordagens clássicas utilizam um passo fixo (limitado pelo inverso da constante de Lipschitz do operador suave) ou buscas inexatas adaptativas, como o *backtracking*. No entanto, em aplicações de larga escala como a TC, o cálculo exato da constante de Lipschitz não possui fórmula analítica fechada e sua aproximação numérica pode ser custosa, enquanto a busca inexata por *backtracking* diminui a eficiência computacional devido às repetidas avaliações do operador de projeção.

Como a parcela suave continua sendo quadrática, surge a hipótese de que um passo calculado exclusivamente para essa parcela possa acelerar a convergência dos métodos proximais. Com isso, este projeto investiga a utilização de uma busca linear exata, calculada analiticamente de forma relativamente barata, considerando apenas a parcela quadrática da função objetivo. Especificamente, este trabalho tem como objetivos: (i) avaliar a busca exata em problemas quadráticos irrestritos, comparando-a às estratégias de passo fixo, *backtracking* e ao método dos gradientes conjugados; (ii) otimizar algebricamente seu cálculo em tomografia computadorizada; (iii) analisar a eficácia dessa forma de calcular o tamanho de passo em problemas regularizados por normas não suaves (ℓ_1 *wavelet* e variação total); e (iv) avaliar o comportamento dos algoritmos, ponderando se a eliminação do custo iterativo do *backtracking* compensa os eventuais impactos na estabilidade e convergência do método.

1.1 ISTA e FISTA

Quando estamos lidando com o problema compósito:

$$\min_{\mathbf{x}} F(\mathbf{x}) = f(\mathbf{x}) + \gamma g(\mathbf{x})$$

onde $f(\mathbf{x})$ é uma função suave e convexa e $g(\mathbf{x})$ é uma função convexa não suave, uma possível forma de resolvê-lo é utilizando o método ISTA (*Iterative Shrinkage-Thresholding Algorithm*). A ideia por

trás deste método é aproveitar a suavidade de f para realizar um passo do gradiente e, em seguida, corrigir o efeito da parte não diferenciável via operador proximal:

Algorithm 1 ISTA

```

1: Entrada:  $\mathbf{x}_0 \in \mathbb{R}^n, \lambda > 0$ .
2: for  $k = 0, 1, 2, \dots$  do
3:    $\mathbf{x}_{k+1} = \text{prox}_{\gamma\lambda g}(\mathbf{x}_k - \lambda \nabla f(\mathbf{x}_k))$ 
4: end for
5: Retorno: Solução aproximada  $\mathbf{x}^*$ .

```

Uma variação mais eficiente desse algoritmo é o FISTA (*Fast Iterative Shrinkage-Thresholding Algorithm*) [1], que utiliza o *momentum* de Nesterov para acelerar a convergência:

Algorithm 2 FISTA

```

1: Entrada:  $\mathbf{x}_0 \in \mathbb{R}^n, \lambda > 0$ .
2: Inicialização:  $\mathbf{y}_1 = \mathbf{x}_0, t_1 = 1$ .
3: for  $k = 1, 2, \dots$  do
4:    $\mathbf{x}_k = \text{prox}_{\gamma\lambda g}(\mathbf{y}_k - \lambda \nabla f(\mathbf{y}_k))$ 
5:    $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$ 
6:    $\mathbf{y}_{k+1} = \mathbf{x}_k + \left(\frac{t_k - 1}{t_{k+1}}\right)(\mathbf{x}_k - \mathbf{x}_{k-1})$ 
7: end for
8: Retorno: Solução aproximada  $\mathbf{x}^*$ .

```

Quando a constante de Lipschitz não é conhecida ou o seu cálculo direto é inviável, utiliza-se a estratégia de busca inexata por *backtracking*. Nesse cenário, busca-se um tamanho de passo λ que satisfaça o critério de descida suficiente:

$$f(\mathbf{x}_k) \leq f(\mathbf{y}_k) + \langle \nabla f(\mathbf{y}_k), \mathbf{x}_k - \mathbf{y}_k \rangle + \frac{1}{2\lambda} \|\mathbf{x}_k - \mathbf{y}_k\|_2^2$$

onde $\mathbf{x}_k = \text{prox}_{\gamma\lambda g}(\mathbf{y}_k - \lambda \nabla f(\mathbf{y}_k))$. Se a condição falhar, o passo λ é reduzido por um fator de contração $\beta \in (0, 1)$ até que a inequação seja satisfeita.

Neste trabalho, focamos em duas opções para a regularização $g(\mathbf{x})$:

1. **Norma ℓ_1 no domínio Wavelet:** $g(\mathbf{x}) = \|\mathbf{H}\mathbf{x}\|_1$, onde $\mathbf{H}$ é uma transformada *wavelet* ortonormal. Nesse caso, o operador proximal possui fórmula fechada:

$$\text{prox}_{\lambda\gamma g}(\mathbf{x}) = \mathbf{H}^T \mathcal{S}_{\lambda\gamma}(\mathbf{H}\mathbf{x})$$

onde $\mathcal{S}_{\lambda\gamma}$ é o operador de *soft-thresholding*.

2. **Variação Total (TV):** Quando $g(\mathbf{x}) = TV(\mathbf{x})$ para imagens bidimensionais $\mathbf{x} \in \mathbb{R}^{m \times n}$.

$$TV(\mathbf{x}) = \sum_{i=1}^{m-1} \sum_{j=1}^{n-1} \sqrt{(x_{i,j} - x_{i+1,j})^2 + (x_{i,j} - x_{i,j+1})^2} \\ + \sum_{i=1}^{m-1} |x_{i,n} - x_{i+1,n}| + \sum_{j=1}^{n-1} |x_{m,j} - x_{m,j+1}|$$

Nesse caso, como não existe fórmula fechada para o operador proximal, utilizou-se o algoritmo rápido FGP (*Fast Gradient Projection*) apresentado em [2].

2 Metodologia

Os métodos foram implementados em Python, utilizando as bibliotecas SciPy, NumPy, Matplotlib, PyTorch, PyWavelets, Scikit-Image e SigPy, rodando em um processador Intel Core i5-13420H com 8 GB de RAM e uma GPU RTX 3050 (6 GB de VRAM). Para computar a Transformada de Radon e seus operadores adjuntos de maneira eficiente em experimentos de tomografia, adotou-se a biblioteca desenvolvida pelo Prof. Elias Salomão Helou Neto, disponível em https://github.com/elias-helou/ray_tracing. Todo o código-fonte, implementações, experimentos mencionados ao longo das próximas seções, além de alguns outros encontram-se disponíveis em nosso repositório no GitHub: https://github.com/gligabo/projeto_ic.

Cabe ressaltar que as simulações envolvendo tomografia computadorizada (TC) foram executadas na GPU, o que reduziu significativamente o tempo de processamento e viabilizou a repetição de cada experimento 5 vezes (sendo os tempos reportados em média e desvio padrão). Em contrapartida, os experimentos de restauração de imagens foram executados inteiramente em CPU. Devido ao elevado custo computacional e ao tempo de execução restritivo nestes cenários, optou-se por realizar uma única execução para as métricas reportadas.

2.1 Problemas sem Regularização

Para os problemas sem regularização (*deblurring* e tomografia livres de ruído), resolvemos o problema de mínimos quadrados:

$$\min_{\mathbf{x}} f(\mathbf{x}) = \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2$$

Nesse cenário é conhecido que o mínimo global satisfaz $f(\mathbf{x}^*) = 0$. Portanto adotou-se o valor da própria função objetivo $f(\mathbf{x})$ como critério de parada para comparação padronizada entre os algoritmos. No caso do *deblurring*, utilizou-se a imagem de teste *coffee* (biblioteca *scikit-image*) com operador

A modelado por convolução com kernel de média de dimensões 7×7 . Em tomografia, utilizou-se o fantoma de Shepp-Logan de dimensões 512×512 .

2.2 Problemas com Regularização

Para problemas com ruído nas medições, formulou-se a minimização compósita:

$$\min_{\mathbf{x}} F(\mathbf{x}) = \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \gamma g(\mathbf{x})$$

onde $g(\mathbf{x})$ representa a regularização por norma ℓ_1 no domínio *wavelet* (utilizando a base de Daubechies) ou por Variação Total (TV). O critério de parada adotado para estes cenários foi a diferença euclidiana entre iterados sucessivos, $\|\mathbf{x}_k - \mathbf{x}_{k-1}\|_F \leq \text{tol}$.

Para a restauração de imagens (*deblurring* e *denoising*), utilizou-se a imagem *astronaut* (biblioteca *scikit-image*) corrompida por um operador de convolução com kernel de média de dimensões 7×7 e ruído aditivo gaussiano com média zero e desvio padrão $\sigma = 0.01$. A constante Lipschitz estimada foi $L_f = 0.9997$, garantindo os limites teóricos de convergência para passos fixos ($\lambda = 1$). No cenário de tomografia regularizada, adicionou-se ruído gaussiano equivalente a 5% do valor máximo da projeção ($\sigma = 0.05 \times \max(\mathbf{b})$), a constante Lipschitz estimada foi $L_f = 3.82$, sendo assim utilizou-se um tamanho de passo $\lambda = 0.2$, já que a convergência é garantida. Em todas as simulações em que as imagens contêm ruído, fixou-se a semente aleatória para assegurar reprodutibilidade. No cálculo do operador proximal de variação total, que não possui fórmula analítica explícita, empregaram-se 15 iterações internas do algoritmo FGP em cada avaliação proximal do modelo.

2.3 Estimativa da Constante de Lipschitz

Como não há fórmula fechada para a norma espectral dos operadores envolvidos, a constante L_f foi estimada numericamente de forma prévia à otimização, uma única vez por cenário experimental. Nos experimentos de tomografia computadorizada, executados em GPU, empregou-se o método das potências aplicado ao operador $\mathbf{Q} = \mathbf{A}^T \mathbf{A}$ de forma *matrix-free*, com até 50 iterações e tolerância de 10^{-6} . Já nos experimentos de restauração de imagens, executados em CPU, a norma espectral foi obtida via decomposição de Lanczos (*SciPy*), utilizando o mesmo operador $\mathbf{Q}$.

2.4 Otimização Computacional da Busca Linear Exata

Para reduzir o custo computacional por iteração da busca linear exata no método de Nesterov, implementou-se uma otimização algébrica na determinação do tamanho de passo. O passo exato na

direção do gradiente negativo $\nabla f(\mathbf{x}_k)$ para o problema de mínimos quadrados é dado por:

$$\lambda_k = \frac{\nabla f(\mathbf{x}_k)^T \nabla f(\mathbf{x}_k)}{\nabla f(\mathbf{x}_k)^T \mathbf{Q} \nabla f(\mathbf{x}_k)}$$

onde $\mathbf{Q} = \mathbf{A}^T \mathbf{A}$. A implementação direta dessa estratégia aplica o operador $\mathbf{Q}$ diretamente no gradiente, o que exige duas passagens pela Transformada de Radon (uma projeção e uma retroprojeção). No entanto, podemos reescrever o denominador como:

$$\nabla f(\mathbf{x}_k)^T \mathbf{Q} \nabla f(\mathbf{x}_k) = \nabla f(\mathbf{x}_k)^T (\mathbf{A}^T \mathbf{A}) \nabla f(\mathbf{x}_k) = \|\mathbf{A} \nabla f(\mathbf{x}_k)\|_2^2$$

Essa equivalência matemática permite substituir o cálculo de $\mathbf{Q}(\nabla f(\mathbf{x}_k))$ por apenas $\mathbf{A}(\nabla f(\mathbf{x}_k))$, reduzindo pela metade as operações de transformação geométrica no cálculo do passo. Essa otimização foi aplicada apenas nos experimentos de TC, dado o maior foco deste trabalho.

3 Resultados

3.1 Problemas Quadráticos (Sem Regularização)

3.1.1 Deblurring de Imagens

Os métodos analisados e comparados foram os seguintes: Máxima Descida com Passo Fixo (MDPF) e com Busca Linear Exata (MDBE), Nesterov com Passo Fixo, com *Backtracking* e com Busca Linear Exata, além dos Gradientes Conjugados (GC).

Inicialmente, com limite de 1000 iterações e tolerância de 10^{-2} para o valor de $f(\mathbf{x})$, avaliamos o número de iterações, o tempo computacional e o PSNR da imagem recuperada, conforme sumarizado na Tabela 1.

Tabela 1: Convergência e Reconstrução no *Deblurring* sem Regularização (tol = 10^{-2})

Método	Iterações	Tempo (s)	PSNR (dB)
Máxima Descida Passo Fixo ($\lambda = 1$)	1000	41.64	30.40
Máxima Descida Busca Exata	849	58.73	31.23
Nesterov Passo Fixo ($\lambda = 1$)	109	4.80	31.25
Nesterov Busca Exata	94	6.51	31.25
Nesterov Backtracking ($\lambda_0 = 1.2$)	99	6.85	31.24
Gradientes Conjugados	59	4.85	31.37

A análise empírica inicial do tamanho de passo fixo (Figura 1 no Apêndice) fez com que a escolha fosse de $\lambda = 1$. Além disso essa escolha foi corroborada através da estimação da constante de Lipschitz

($L_f = 0.9997$). Observando as curvas de decaimento do erro pelas iterações (Figura 2) e ao longo do tempo de execução (Figura 3), observa-se que a busca linear exata em métodos acelerados de Nesterov converge em menos iterações e em menor tempo que utilizando *backtracking*.

Para aprofundar essa comparação entre as duas estratégias adaptativas de passo no método de Nesterov (busca exata vs. *backtracking*), realizou-se um experimento fixando 200 iterações. Nesse contexto, o Nesterov com busca exata atingiu o limite de iterações em 13.35 segundos, enquanto o Nesterov com *backtracking* levou 13.63 segundos. A superioridade da busca exata deve-se à eliminação da rotina iterativa de verificação da desigualdade do critério de descida suficiente. Enquanto o *backtracking* necessita avaliar repetidamente a função objetivo $f(\mathbf{x}_k)$ a cada tentativa de redução do passo λ , o passo exato calcula analiticamente o tamanho de passo ótimo em apenas uma avaliação em forma fechada na direção de descida. Conforme ilustrado no comparativo visual de reconstrução na Figura 5, a busca exata proporciona um maior valor de PSNR e estabilidade numérica idêntica ou superior ao *backtracking*.

Ainda assim, para esse problema puramente quadrático e sem restrições, o método dos gradientes conjugados obteve o melhor desempenho na combinação de tempo de execução, número de iterações e qualidade visual. Fixando um número máximo de 200 iterações (Tabela 2), por mais que o GC tenha demorado mais tempo, a sua superioridade fica clara na avaliação visual apresentada na Figura 4 no Apêndice.

Tabela 2: Comparação de Tempo com Limite Fixo de 200 Iterações

Método	Iterações	Tempo (s)
Máxima Descida Passo Fixo	200	8.08
Máxima Descida Busca Exata	200	13.44
Nesterov Passo Fixo	200	8.11
Nesterov Busca Exata	200	13.35
Nesterov Backtracking	200	13.63
Gradientes Conjugados	200	16.02

Por fim, em um cenário com tolerância de 10^{-5} e limite de 1500 iterações (Tabela 3), o gradiente conjugado alcançou a convergência em 61.34 segundos (755 iterações), contrastando com 88.44 segundos (1317 iterações) do método de Nesterov com busca exata. A fidelidade final de reconstrução dessa comparação direta pode ser conferida na Figura 6.

Tabela 3: Comparação Longa: Nesterov Busca Exata vs Gradientes Conjugados

Método	Iterações	Tempo (s)
Nesterov Busca Exata	1317	88.44
Gradientes Conjugados	755	61.34

3.1.2 Tomografia Computadorizada

Na reconstrução tomográfica sem regularização do fantoma Shepp-Logan (512×512), a norma do operador de Radon foi de $L \approx 3.82$, portanto foi escolhido passo fixo de $\lambda = 0.2$. O tempo, o número de iterações e o PSNR da imagem que minimiza o valor da função objetivo estão registrados na Tabela 4 (médias de 5 execuções). Além disso, os gráficos de decaimento do erro por iteração, tempo e as reconstruções com seus respectivos valores de PSNR podem ser observados nas Figuras 19, 20 e 21.

Tabela 4: Convergência em Tomografia sem Regularização ($\text{tol} = 10^{-2}$)

Método	Iterações	Tempo (s)	PSNR (dB)
Máxima Descida Passo Fixo	1000	14.37 ± 0.05	32.23
Máxima Descida Busca Exata	1000	16.97 ± 0.84	33.73
Nesterov Passo Fixo	212	3.05 ± 0.00	34.39
Nesterov Backtracking	212	4.86 ± 0.02	34.39
Nesterov Busca Exata	152	2.80 ± 0.00	34.30
Gradientes Conjugados	46	0.68 ± 0.01	33.81

Restringindo o custo a exatamente 200 iterações (Tabela 5), o gradiente conjugado produziu a melhor reconstrução (PSNR 37.42 dB), seguido pelo de Nesterov com busca exata (34.83 dB). No entanto, o ganho de velocidade da busca exata comparado ao *backtracking* é relevante no método de Nesterov. Os gráficos de decaimento do erro por iteração, tempo e os as reconstruções com seus respectivos valores de PSNR podem ser observados nas Figuras 22, 23 e 24.

Tabela 5: Desempenho em Tomografia com 200 Iterações

Método	Tempo (s)	PSNR (dB)
Máxima Descida Passo Fixo	2.34 ± 0.01	23.31
Máxima Descida Busca Exata	3.00 ± 0.01	30.35
Nesterov Passo Fixo	2.35 ± 0.01	33.66
Nesterov Backtracking	4.14 ± 0.05	33.66
Nesterov Busca Exata	3.05 ± 0.03	34.83
Gradientes Conjugados	2.56 ± 0.02	37.42

A Tabela 6 ilustra a comparação em regimes de tolerância de precisão elevada (10^{-4} e 10^{-5}), confirmando que os gradientes conjugados são a melhor escolha no cenário de problemas quadráticos. As reconstruções com seus valores de PSNR podem ser observadas na Figura 25 e 26 para cada um desses dois experimentos.

Tabela 6: Nesterov Busca Exata vs Gradientes Conjugados (Alta Precisão)

Tolerância	Método	Iterações	Tempo (s)	PSNR (dB)
1.0×10^{-4}	Nesterov Busca Exata	843	12.96 ± 0.36	38.56
	Gradientes Conjugados	292	3.96 ± 0.07	38.49
1.0×10^{-5}	Nesterov Busca Exata	1500*	25.38 ± 1.80	40.17
	Gradientes Conjugados	736	11.16 ± 0.03	40.98

*Atingiu o limite máximo de iterações sem alcançar a tolerância.

Impacto da Otimização Computacional Conforme detalhado na metodologia, aplicou-se uma otimização algébrica no cálculo do passo exato para os experimentos de TC. Os resultados práticos dessa abordagem, evidenciados na Tabela 7, indicaram uma redução sistemática no tempo de execução, alcançando ganhos de até aproximadamente 24% em relação à implementação direta.

Tabela 7: Impacto da Otimização Algébrica do Passo no Tempo Computacional

Iterações	Sem Otimização (s)	Com Otimização (s)	Ganho Computacional
500	10.07 ± 0.04	7.59 ± 0.02	24.63%
1000	20.53 ± 0.22	16.04 ± 0.15	21.87%

3.2 Problemas Regularizados

Nesta seção, avalia-se a restauração de imagens borradas e corrompidas por ruído gaussiano ($\sigma = 0.01$) bem como a tomografia computadorizada ruidosa.

3.2.1 Regularização no Domínio *Wavelet* (ℓ_1)

Deblurring de Imagens Para selecionar o parâmetro de regularização no domínio *wavelet*, realizou-se um *grid-search*, sendo $\gamma^* = 0.001$ (Figura 7) o valor ótimo que minimiza o erro em relação à imagem original. Em um primeiro teste com $\gamma = 0.001$, limite de 250 iterações e tolerância $\text{tol} = 10^{-2}$, os métodos foram comparados (Tabela 8).

Tabela 8: Desempenho no *Deblurring* com Ruído e Regularização *Wavelet* ($\gamma = 0.001$, 250 it.)

Método	Iterações	Tempo (s)
ISTA Fixo ($\lambda = 1$)	250*	19.86
FISTA Fixo ($\lambda = 1$)	250*	20.52
ISTA Exato	250*	33.21
FISTA Exato	250*	34.23
FISTA Backtracking	250*	34.79

*Nenhum algoritmo atingiu o critério $\|\mathbf{x}_k - \mathbf{x}_{k-1}\|_F \leq 10^{-2}$ antes de 250 iterações.

Apesar de o operador linear ser ortonormal, o FISTA utilizando passo exato não converge. Os gráficos de decaimento de erro em relação ao mínimo numérico $F(\mathbf{x}^*)$ (onde $\mathbf{x}^*$ é o iterado que minimiza a função objetivo dentre todos os algoritmos avaliados na respectiva comparação) e de variação entre iterados (Figuras 8 e 9) mostram que o fato do cálculo analítico do passo exato se basear unicamente na parcela quadrática faz com que os passos λ_k fiquem muito grandes (Figura 10), não preservando as garantias teóricas de convergência dos algoritmos.

Para compreender a sensibilidade à escolha do parâmetro de regularização, rodaram-se testes para diferentes valores de γ . A Tabela 9 reporta o comportamento dos algoritmos e o PSNR máximo obtido pelas reconstruções do FISTA com *Backtracking*.

Tabela 9: Comportamento Computacional de ISTA/FISTA e Qualidade por γ (*Wavelet*)

Gamma	ISTA Exato	ISTA Fixo	FISTA Exato	FISTA Backtracking	PSNR (dB)
0.0001	250 it. (32.30 s)	250 it. (20.56 s)	250 it. (34.21 s)	250 it. (34.98 s)	14.13
0.001	250 it. (34.20 s)	250 it. (23.59 s)	250 it. (34.63 s)	250 it. (34.99 s)	26.91
0.01	250 it. (34.74 s)	200 it. (18.51 s)	250 it. (34.58 s)	124 it. (17.15 s)	25.35
0.1	58 it. (7.91 s)	81 it. (8.08 s)	250 it. (34.78 s)	62 it. (8.48 s)	23.18
0.2	51 it. (6.85 s)	67 it. (6.44 s)	250 it. (34.49 s)	54 it. (7.19 s)	22.05

Analisando as Figuras 11 e 12, observa-se que, para $\gamma \rightarrow 0$ (e.g., $\gamma = 0.0001$), o problema aproxima-se do caso quadrático, e as estratégias de busca linear exata (ISTA Exato e FISTA Exato) conseguem atingir menores valores de $F(x_k) - F^*$ em 250 iterações quando comparadas às abordagens de passo fixo ou *backtracking*. Contudo, essa redução ocorre de maneira instável, com oscilações severas entre iterações consecutivas. Para valores intermediários de γ , que produzem as melhores reconstruções em termos de PSNR, ambos os métodos oscilam e não conseguem reduzir o erro de maneira consistente. Já para $\gamma \geq 0.1$, o ISTA Exato volta a convergir de forma estável, visto que o alto valor de γ força o *soft-thresholding* a zerar múltiplos coeficientes, tornando a representação esparsa no domínio *wavelet* e assim restringindo o espaço de busca. O FISTA Exato, porém, permanece instável mesmo nesse cenário, indicando que o *momentum* de Nesterov amplifica as violações do passo de forma persistente, superando o efeito estabilizador da forte regularização.

Tomografia Computadorizada No problema de Tomografia com ruído gaussiano (5%) e regularização ℓ_1 no domínio *wavelet*, o valor ótimo escolhido através do *grid-search* foi $\gamma = 0.005$ (Figura 27). A Tabela 10 exibe os tempos totais após 1000 iterações ($\lambda = 0.2$ para FISTA Fixo e para o início do *Backtracking*).

Tabela 10: Tempos de Reconstrução em Tomografia Regularizada (*Wavelets*, 1000 it.)

Método	Tempo (s)	Iterações
FISTA Fixo	17.14 ± 0.20	1000
ISTA Exato	21.07 ± 0.52	1000
FISTA Exato	21.38 ± 0.54	1000
FISTA Backtracking	26.63 ± 0.32	1000

A análise evolutiva do erro entre iterados na Figura 28 indica que os algoritmos de busca exata em tomografia começam a oscilar indefinidamente ao atingirem um certo patamar de erro, não satisfazendo o critério de parada adotado. Esse comportamento oscilatório também compromete a convergência da função objetivo $F(\mathbf{x}_k) - F^*$ (Figura 29).

Por outro lado, ao monitorarmos a curva de PSNR ao longo do tempo (Figura 30), nota-se um fenômeno de semi-convergência. O FISTA Exato atinge o valor de PSNR máximo (25.3 dB) mais rapidamente do que os demais métodos (Tabela 11), superando em especial o FISTA Backtracking, que perde eficiência em virtude das sucessivas avaliações da função objetivo necessárias para satisfazer o critério de descida suficiente. As respectivas imagens correspondentes às soluções que melhor minimizam a função objetivo podem ser conferidas na Figura 31.

Tabela 11: Tempo para Atingir o Pico Máximo de Qualidade (PSNR de 25.3 dB)

Método	Tempo (s)
FISTA Exato	0.92
FISTA Fixo	1.01
FISTA Backtracking	1.57
ISTA Exato	1.71

Essas observações se mantiveram frente a variações do parâmetro de regularização, do chute inicial ($\mathbf{x}_0 = \mathbf{0}$ ou $\mathbf{x}_0 = \mathbf{A}^T \mathbf{b}$) e das tolerâncias. Em todos os cenários adicionais, sumarizados nas Tabelas 12 e 13, os algoritmos com estratégia de busca exata mantêm-se oscilando, mas preservam o fenômeno de semi-convergência acelerada nas primeiras iterações.

Tabela 12: Convergência Temporal e Iterativa sob Variação de Cenários de Tomografia

Configuração Experimental	FISTA Fixo	ISTA Exato	FISTA Exato
$\gamma = 0.01, \text{tol} = 10^{-3}, \mathbf{x}_0 = \mathbf{0}$	12.49 $\pm$ 0.16 s (717 it.)	20.95 $\pm$ 0.28 s (1000 it.)	21.20 $\pm$ 0.31 s (1000 it.)
$\gamma = 0.005, \text{tol} = 10^{-2}, \mathbf{x}_0 = \mathbf{0}$	6.98 $\pm$ 0.30 s (370 it.)	20.96 $\pm$ 0.17 s (1000 it.)	21.16 $\pm$ 0.17 s (1000 it.)
$\gamma = 0.005, \text{tol} = 10^{-2}, \mathbf{x}_0 = \mathbf{A}^T \mathbf{b}$	6.63 $\pm$ 0.26 s (367 it.)	21.68 $\pm$ 0.14 s (1000 it.)	21.56 $\pm$ 0.25 s (1000 it.)

Tabela 13: Métricas de Tempo ao PSNR Máximo nos Cenários Variáveis de Tomografia

Configuração Experimental	FISTA Fixo	ISTA Exato	FISTA Exato
$\gamma = 0.01, \text{tol} = 10^{-3}, \mathbf{x}_0 = \mathbf{0}$	1.08 s (24.5 dB)	6.90 s (24.5 dB)	0.98 s (24.6 dB)
$\gamma = 0.005, \text{tol} = 10^{-2}, \mathbf{x}_0 = \mathbf{0}$	1.12 s (25.3 dB)	1.70 s (25.3 dB)	0.91 s (25.3 dB)
$\gamma = 0.005, \text{tol} = 10^{-2}, \mathbf{x}_0 = \mathbf{A}^T \mathbf{b}$	1.07 s (25.3 dB)	1.65 s (25.3 dB)	0.93 s (25.3 dB)

3.2.2 Regularização por Variação Total (TV)

Deblurring de Imagens Na regularização por variação total (TV), repetiu-se o *grid-search*, encontrando $\gamma^* = 0.001$ como valor ótimo (Figura 13). Para o cálculo do operador proximal de TV (não possui fórmula analítica fechada), executaram-se 15 iterações do algoritmo FGP em cada avaliação. A Tabela 14 documenta o desempenho com $\gamma = 0.001$, tolerância de 10^{-3} e limite de 500 iterações. Além disso, os gráficos de decaimento de erro em relação ao mínimo numérico e de variação entre iterados podem ser vistos nas Figuras 14 e 15.

Tabela 14: Desempenho no *Deblurring* com Ruído e Regularização TV ($\gamma = 0.001$, 500 it., $\text{tol} = 10^{-3}$)

Método	Iterações	Tempo (s)
ISTA Fixo ($\lambda = 1$)	500*	94.38
FISTA Fixo ($\lambda = 1$)	500*	96.51
ISTA Exato	500*	115.08
FISTA Exato	500*	115.57
FISTA Backtracking	500*	115.38

*Todos atingiram o limite máximo de 500 iterações.

Avaliou-se ainda o comportamento dos algoritmos para diferentes valores de γ , com limite de 250 iterações e $\text{tol} = 10^{-2}$ (Tabela 15).

Tabela 15: Comportamento Computacional por γ na Regularização TV

Gamma	ISTA Exato	FISTA Exato	ISTA Fixo	FISTA Fixo
0.001	250 it. (60.31 s)	250 it. (58.01 s)	250 it. (45.75 s)	187 it. (34.22 s)
0.01	250 it. (57.31 s)	250 it. (59.03 s)	174 it. (32.47 s)	107 it. (20.14 s)
0.1	66 it. (15.37 s)	250 it. (58.85 s)	95 it. (17.80 s)	62 it. (11.51 s)
0.2	35 it. (8.03 s)	250 it. (58.79 s)	59 it. (10.83 s)	44 it. (8.16 s)

A análise com TV corrobora os achados para as *wavelets*, como pode ser visto nas Figuras 16 e 17. O passo analítico calculado de forma exata para formulações quadráticas não preserva as garantias teóricas quando utilizado em problemas regularizados. O monitoramento do passo no último iterado com TV (quando $\gamma = 0.001$) revelou valores de $\lambda_{\text{ISTA}} \approx 1.9981$ e $\lambda_{\text{FISTA}} \approx 1.3374$. Curiosamente, mesmo que o ISTA Exato não tenha ultrapassado o limiar de Lipschitz ($\lambda < 2/L = 2.0006$), ele revelou severa instabilidade. Isso sugere que, ainda assim, os tamanhos de passo calculado estão sendo muito agressivos.

Tomografia Computadorizada Para o cenário de tomografia computadorizada regularizada por variação total (TV), realizou-se inicialmente um *grid-search* para encontrar o valor do parâmetro de regularização, sendo $\gamma = 0.005$ identificado como o que minimiza o erro em relação ao fantoma original (Figura 32).

O primeiro teste comparou o desempenho dos métodos com uma tolerância de 10^{-3} e um limite de 1000 iterações. O tamanho de passo utilizado para os algoritmos de passo fixo e *backtracking* foi $\lambda = 0.2$ e o chute inicial $\mathbf{x}_0 = \mathbf{0}$. Os resultados desse experimentos, calculados a partir de 5 execuções independentes, podem ser vistos na Tabela 16.

Tabela 16: Convergência Temporal em Tomografia com Variação Total ($\gamma = 0.005$, $\text{tol} = 10^{-3}$)

Método	Tempo (s)	Iterações
FISTA Fixo	14.71 $\pm$ 0.02	848
FISTA Backtracking	17.61 $\pm$ 1.04	668
ISTA Exato	20.71 $\pm$ 0.03	1000*
FISTA Exato	20.78 $\pm$ 0.04	1000*

*Atingiu o limite máximo de iterações sem estabilizar no critério de parada.

Da mesma forma que observado na regularização por *wavelets*, a instabilidade numérica da busca linear exata em tomografia por variação total compromete fortemente a convergência assintótica. Nas Figuras 33 e 34, observa-se que os métodos ISTA Exato e FISTA Exato perdem estabilidade e passam a oscilar sistematicamente, não conseguindo minimizar o valor da função objetivo e nem a diferença dos iterados.

Contudo, ao monitorarmos a evolução do PSNR (Figura 35) e examinarmos o tempo e a rapidez com que cada método alcança o seu valor de pico (Tabela 17), observa-se novamente que o FISTA Exato atinge o valor máximo (30.9 dB) com maior velocidade inicial (1.29 s) que o FISTA Fixo (1.60 s) e significativamente mais rápido que o ISTA Exato e o FISTA com *Backtracking*. As respectivas imagens correspondentes às soluções que melhor minimizam a função objetivo podem ser conferidas na Figura 36.

Tabela 17: Tempo para Atingir o PSNR Máximo de Reconstrução ($\gamma = 0.005$)

Método	Tempo (s)	PSNR Máximo (dB)
FISTA Exato	1.29	30.9
FISTA Fixo	1.60	30.9
FISTA Backtracking	2.43	30.9
ISTA Exato	20.54	30.7

Para verificar a robustez e se esse comportamento é geral ou um acaso, efetuaram-se três experimentos complementares: (i) aumento da regularização para $\gamma = 0.01$; (ii) relaxamento da tolerância de convergência para $\text{tol} = 10^{-2}$ mantendo $\gamma = 0.005$; e (iii) alteração do vetor inicial para a retroprojeção direta dos dados medidos, $\mathbf{x}_0 = \mathbf{A}^T \mathbf{b}$. Os resultados são exibidos nas Tabelas 18 e 19.

Tabela 18: Convergência Temporal em Diferentes Cenários de Tomografia com TV

Cenário Experimental	FISTA Fixo	ISTA Exato	FISTA Exato
$\gamma = 0.01, \text{tol} = 10^{-3}, \mathbf{x}_0 = \mathbf{0}$	13.24 $\pm$ 0.01 s (763 it.)	20.69 $\pm$ 0.00 s (1000 it.)	20.77 $\pm$ 0.01 s (1000 it.)
$\gamma = 0.005, \text{tol} = 10^{-2}, \mathbf{x}_0 = \mathbf{0}$	5.27 $\pm$ 0.01 s (304 it.)	20.70 $\pm$ 0.03 s (1000 it.)	20.79 $\pm$ 0.01 s (1000 it.)
$\gamma = 0.005, \text{tol} = 10^{-2}, \mathbf{x}_0 = \mathbf{A}^T \mathbf{b}$	5.24 $\pm$ 0.01 s (302 it.)	20.69 $\pm$ 0.01 s (1000 it.)	20.86 $\pm$ 0.05 s (1000 it.)

Tabela 19: Tempo para Atingir o PSNR Máximo em Cenários Variáveis com TV

Cenário Experimental	FISTA Fixo	ISTA Exato	FISTA Exato
$\gamma = 0.01, \text{tol} = 10^{-3}, \mathbf{x}_0 = \mathbf{0}$	1.34 s (29.9 dB)	7.83 s (29.4 dB)	1.12 s (29.8 dB)
$\gamma = 0.005, \text{tol} = 10^{-2}, \mathbf{x}_0 = \mathbf{0}$	1.60 s (30.9 dB)	13.72 s (29.4 dB)	1.29 s (30.9 dB)
$\gamma = 0.005, \text{tol} = 10^{-2}, \mathbf{x}_0 = \mathbf{A}^T \mathbf{b}$	1.60 s (30.9 dB)	20.51 s (29.4 dB)	1.32 s (30.9 dB)

Os testes efetuados indicam que a conclusão para a variação total acompanha os resultados das *wavelets*. A estabilidade assintótica das estratégias com passo exato é prejudicada pelo fato de a expressão analítica ignorar a geometria do termo de regularização, culminando em oscilações severas que impedem a redução do valor da função objetivo e a estabilização da diferença entre os iterados, como registrado na Figura 34. No entanto, o fenômeno pontual de semi-convergência precoce do FISTA

Exato se mantém robusto em problemas de regularização por variação total, alcançando a imagem reconstruída de forma mais ágil que métodos de passo fixo ou com *backtracking*.

3.2.3 Comparação de Reconstrução: Variação Total vs. Wavelets

Para confrontar a qualidade visual das reconstruções entre TV e *wavelets*, conduziu-se um experimento padronizado fixando $\gamma = 0.01$, passo base $\lambda = 1$, $\text{tol} = 10^{-2}$ e um limite de 200 iterações (Tabela 20).

Tabela 20: Confronto Direto de Reconstrução no *Deblurring* ($\gamma = 0.01$, 200 it.)

Método Regularizado	Iterações	Tempo (s)
FISTA Fixo TV ($\lambda = 1$)	107	22.50
FISTA Exato TV	200*	48.95
FISTA Exato Wavelet	200*	27.80
FISTA Fixo Wavelet ($\lambda = 1$)	125	11.99

*Atingiu o limite de 200 iterações.

A comparação visual correspondente está exibida na Figura 18. Nota-se que, enquanto o FISTA Fixo converge estavelmente em ambos os modelos, a busca exata consome mais que o dobro do tempo de execução, em razão de não conseguir atingir o critério de parada. Além disso, a reconstrução com a TV retorna imagens com melhores métricas (PSNR e SSIM), o que é consistente com a literatura já que a TV preserva melhor as bordas das imagens.

4 Conclusão

Neste trabalho, avaliamos empiricamente a influência da substituição das estratégias convencionais de tamanho de passo (passo fixo e *backtracking*) pelo cálculo analítico da busca linear exata na parcela quadrática em algoritmos de gradiente proximal acelerado de primeira ordem. Os experimentos foram estruturados de forma incremental, abrangendo desde problemas quadráticos irrestritos até formulações de problemas regularizados com normas não diferenciáveis (*wavelets* ℓ_1 e variação total) aplicadas à restauração de imagens e à tomografia computadorizada.

No contexto puramente quadrático sem regularização (*deblurring* e TC livres de ruído), a busca linear exata provou ser computacionalmente vantajosa ao eliminar as sucessivas avaliações da função objetivo exigidas pelo critério de descida suficiente do *backtracking*. A otimização algébrica implementada, que reformula o denominador do passo analítico em função da norma de projeção direta $\|\mathbf{A}\nabla f(\mathbf{x}_k)\|_2^2$, reduziu pela metade as chamadas ao operador adjunto (retroprojeção na TC), gerando uma economia média de até 24,63% no tempo de execução do método de Nesterov. Contudo,

constatou-se que, na ausência de termos regularizadores não suaves, o método dos gradientes conjugados permanece superior, superando todas as variantes de Nesterov em velocidade, número de iterações e fidelidade na reconstrução de imagens.

Por outro lado, ao inserirmos termos de regularização, a busca linear exata apresentou problemas de estabilidade assintótica. Como seu cálculo analítico otimiza exclusivamente a curvatura da parcela suave $f(\mathbf{x})$, o tamanho de passo gerado desconsidera a geometria do termo de regularização. Os resultados indicam que o *momentum* de Nesterov amplifica as violações de passo, causando oscilações que impedem a estabilização do valor da função objetivo e a redução da diferença entre os iterados ao longo do tempo. Consequentemente, para os valores de γ de relevância prática, o algoritmo exibe um comportamento oscilatório, falhando em satisfazer critérios de convergência.

Apesar dessa instabilidade ao longo das iterações, os experimentos revelaram um consistente fenômeno de semi-convergência inicial associado ao FISTA Exato. Em todos os cenários ruidosos e regularizados testados, a agressividade dos passos exatos iniciais levou o algoritmo a atingir o seu valor de pico máximo de PSNR em tempo menor que o FISTA Fixo e o FISTA com *Backtracking*. A regularização por variação total produziu, em geral, imagens com nitidez superior e melhores métricas de reconstrução quando comparada ao domínio *wavelet*, embora cobrando maior custo por iteração devido às resoluções do subproblema de projeção de gradiente.

Uma possível continuidade deste projeto estaria em explorar melhor essa convergência rápida inicial apresentada pelo passo exato, tanto numericamente quanto teoricamente. Estratégias híbridas, como utilizar o FISTA Exato em poucas iterações iniciais como mecanismo de aceleração, passando posteriormente para um passo fixo seguro ou um *backtracking*, podem oferecer um bom meio termo entre eficiência computacional e convergência teórica em problemas inversos de larga escala como a tomografia computadorizada.

Cabe destacar, como limitação deste estudo, que os experimentos foram conduzidos sobre poucas imagens (*coffee* e *astronaut* para *deblurring*, e o fantoma de Shepp-Logan para tomografia), um único operador de borramento/aquisição e o nível de ruído foi mantido o mesmo em todos os testes de uma mesma aplicação. Embora os resultados tenham se mostrado consistentes sob variações do parâmetro de regularização γ , da tolerância e do chute inicial, a generalização das conclusões para outras classes de imagens, operadores de aquisição ou níveis de ruído pode ser mais explorada.

Além do trabalho desenvolvido, haverá a apresentação no 34° SIICUSP (Simpósio de Iniciação Científica da USP), constituindo uma oportunidade para aprimorar as habilidades de comunicação e divulgar este estudo à comunidade científica e acadêmica. A apresentação está programada para o dia 16 de outubro de 2026, no Instituto de Ciências Matemáticas e de Computação (ICMC-USP), em São Carlos.

Referências

- [1] Amir Beck e Marc Teboulle. “A Fast Iterative Shrinkage-Thresholding Algorithm for Linear Inverse Problems”. Em: *SIAM Journal on Imaging Sciences* 2.1 (2009), pp. 183–202. DOI: 10.1137/080716542.
- [2] Amir Beck e Marc Teboulle. “Fast Gradient-Based Algorithms for Constrained Total Variation Image Denoising and Deblurring Problems”. Em: *IEEE Transactions on Image Processing* 18.11 (2009), pp. 2419–2434. DOI: 10.1109/TIP.2009.2028250.
- [3] Heinz W. Engl, Martin Hanke e Andreas Neubauer. *Regularization of Inverse Problems*. Dordrecht, Boston, London: Kluwer Academic Publishers, 2000.
- [4] Jacques Hadamard. “Sur les problèmes aux dérivées partielles et leur signification physique”. Em: *Princeton university bulletin* (1902), pp. 49–52.
- [5] Elias S. Helou e Lucas E. A. Simões. “ ϵ -Subgradient Algorithms for Bilevel Convex Optimization”. Em: *Inverse Problems* 33.5 (2017), p. 055020. DOI: 10.1088/1361-6420/aa6136.
- [6] Elias S. Helou, Marcelo V. W. Zibetti e Gabor T. Herman. “Fast Proximal Gradient Methods for Nonsmooth Convex Optimization for Tomographic Image Reconstruction”. Em: *Sensing and Imaging* 21.45 (2020). DOI: 10.1007/s11220-020-00309-z.
- [7] Elias Salomão Helou Neto e Álvaro Rodolfo De Pierro. “Incremental Subgradients for Constrained Convex Optimization: a Unified Framework and New Methods”. Em: *SIAM Journal on Optimization* 20.3 (2009), pp. 1547–1572. DOI: 10.1137/070711712. URL: <http://link.aip.org/link/?SJE/20/1547/1>.
- [8] Gabor T. Herman. *Image Reconstruction from Projections: The Fundamentals of Computerized Tomography*. Boston (MA): Academic Press, 1980.
- [9] Gerhard van Kaick e Stefan Delorme. “Computed tomography in various fields outside medicine”. Em: *European Radiology Supplements* 15 (2005), pp. d74–d81.
- [10] Avinash C. Kak e Malcolm Slaney. *Principles of Computerized Tomographic Imaging*. New York: IEEE Press, 1988.
- [11] Frank Natterer. *The Mathematics of Computerized Tomography*. Chichester, New York, Brisbane, Toronto, Singapore: John Wiley & Sons Ltd, 1986.
- [12] Frank Natterer e Frank Wübbeling. *Mathematical Methods in Image Reconstruction*. Philadelphia (PA): SIAM, 2001.
- [13] Stanley Osher et al. “An Iterative Regularization Method for Total Variation-Based Image Restoration”. Em: *Multiscale Modeling & Simulation* 4.2 (2005), pp. 460–489. DOI: 10.1137/040605412.

- [14] Eric Todd Quinto. “An introduction to X-ray tomography and Radon transforms”. Em: *Proceedings of symposia in Applied Mathematics*. Vol. 63. 2006, p. 1.
- [15] Johann Radon. “On the determination of functions from their integral values along certain manifolds”. Em: *IEEE Transactions on Medical Imaging* 5.4 (1986), pp. 170–176. DOI: 10.1109/TMI.1986.4307775.
- [16] Leonid I Rudin, Stanley Osher e Emad Fatemi. “Nonlinear total variation based noise removal algorithms”. Em: *Physica D: nonlinear phenomena* 60.1-4 (1992), pp. 259–268.
- [17] Leonid I. Rudin, Stanley Osher e Emad Fatemi. “Nonlinear Total Variation Based Noise Removal Algorithms”. Em: *Physica D: Nonlinear Phenomena* 60.1-4 (1992), pp. 259–268. DOI: 10.1016/0167-2789(92)90242-F. URL: <http://www.sciencedirect.com/science/article/B6TVK-46JYGGT-GH/2/f85f57585ec9af00a1a088d0b8e6d452>.
- [18] Eitan Tadmor, Suzanne Nezzar e Luminita Vese. “A Multiscale Image Representation Using Hierarchical (BV, L^2) Decompositions”. Em: *Multiscale Modeling & Simulation* 2.4 (2004), pp. 554–579. DOI: 10.1137/030600448.
- [19] Andrei N Tikhonov. “Solution of incorrectly formulated problems and the regularization method.” Em: *Sov Dok* 4 (1963), pp. 1035–1038.
- [20] Andrei Nikolaevich Tikhonov e V. I. A. K. Arsenin. “Solutions of ill-posed problems”. Em: *(No Title)* (1977).

A Fundamentação Teórica e Definições Básicas

Definição 1. Um subconjunto $X \subset \mathbb{R}^n$ é dito convexo se, para todo $x, y \in X$ e $\lambda \in [0, 1]$, ele satisfaz que $\lambda x + (1 - \lambda)y \in X$.

Definição 2. Uma função $f : X \rightarrow \mathbb{R}$ em conjunto convexo X é convexa se, para todo $x, y \in X$ e $\lambda \in [0, 1]$:

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

Proposição 1. Seja f uma função de classe C^1 . Ela é convexa em X se, e somente se, para todo $x, y \in X$:

$$f(y) \geq f(x) + \nabla f(x)^T(y - x)$$

Proposição 2. Seja f uma função de classe C^2 em conjunto aberto convexo X . Ela é convexa se, e somente se, para todo $x \in X$, $\nabla^2 f(x) \geq 0$.

Definição 3. O vetor $g \in \mathbb{R}^n$ é um subgradiente de uma função convexa $f : X \rightarrow \mathbb{R}$ em $x \in X$ se:

$$f(y) \geq f(x) + g^T(y - x), \quad \forall y \in X$$

O conjunto de todos os subgradientes em x é denominado subdiferencial, denotado por $\partial f(x)$.

Definição 4. Seja $f : X \rightarrow \mathbb{R}$ convexa e própria. O operador proximal de parâmetro $\lambda > 0$ é:

$$\text{prox}_{\lambda f}(v) = \arg \min_{x \in X} \left\{ f(x) + \frac{1}{2\lambda} \|x - v\|_2^2 \right\}$$

Definição 5. Uma função f é L_f -suave se seu gradiente é Lipschitz contínuo:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L_f \|x - y\|_2$$

Proposição 3. No problema de mínimos quadrados definido por $f(x) = \frac{1}{2} \|Ax - b\|_2^2$, o tamanho de passo que minimiza a função ao longo de uma direção de descida d_k é:

$$\lambda_k = -\frac{\nabla f(x_k)^T d_k}{d_k^T Q d_k}$$

onde $Q = A^T A$.

Proposição 4. Para uma função f convexa e diferenciável com gradiente L_f -Lipschitz contínuo, a desigualdade de descida satisfaz:

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L_f}{2} \|y - x\|_2^2$$

para todo x, y .

Proposição 5. Considere o problema compósito $\min F(x) = f(x) + g(x)$, onde f é convexa com gradiente L_f -Lipschitz e g é convexa e fechada. Para um tamanho de passo $\lambda \in (0, 1/L_f]$, os métodos ISTA e FISTA convergem para o mínimo global da função objetivo com taxas de convergência de $\mathcal{O}(1/k)$ e $\mathcal{O}(1/k^2)$, respectivamente.

Observação 1. A garantia $\lambda \in (0, 1/L_f]$ apresentada acima corresponde à prova clássica de taxa $\mathcal{O}(1/k)$ via lema de decréscimo suficiente [1]. No entanto, para o ISTA, a convergência dos iterados pode ser garantida sob a condição mais fraca $\lambda \in (0, 2/L_f)$. Essa extensão, contudo, não se estende diretamente ao FISTA.

B Gráficos dos Algoritmos

B.1 Métodos sem Regularização




Figura 1: Análise empírica do tamanho de passo fixo.




Figura 2: Evolução da convergência por número de iterações.




Figura 3: Evolução da convergência ao longo do tempo de execução.




Figura 4: Qualidade visual da reconstrução (200 iterações).




Figura 5: Reconstrução sob diferentes estratégias de busca em Nesterov.



Figura 6: Reconstrução com Nesterov Busca Exata vs Gradientes Conjugados.

B.2 Métodos com Regularização (*Wavelets* e TV em Imagens)




Figura 7: Análise de erro (*Grid-Search*) para determinação do parâmetro ótimo $\gamma = 0.001$ (*Wavelets*).




Figura 8: Convergência de $F(x_k) - F(x^*)$ ao longo do tempo (*Wavelets*).




Figura 9: Variação dos iterados $F(x_k) - F(x_{k-1})$ (Wavelets).




Figura 10: Tamanho de passo em modelos com $\gamma = 0.001$ (Wavelets).




Figura 11: Impacto de diferentes valores de γ na distância ao ótimo $F(x^*)$ (Wavelets).




Figura 12: Estabilidade iterativa para diferentes valores de γ (Wavelets).




Figura 13: *Grid-Search* para determinação do parâmetro ótimo $\gamma = 0.001$ (Variação Total).




Figura 14: Convergência de $F(x_k) - F(x^*)$ ao longo do tempo para $\gamma = 0.001$ (Variação Total).




Figura 15: Variação dos iterados $F(x_k) - F(x_{k-1})$ para $\gamma = 0.001$ (Variação Total).




Figura 16: Impacto de diferentes valores de γ na distância ao ótimo $F(x^*)$ (Variação Total).




Figura 17: Estabilidade iterativa para diferentes valores de γ (Variação Total).



Figura 18: Qualidade de Reconstrução comparativa: Variação Total vs. Wavelet ($\gamma = 0.01$, 200 it.).

B.3 Gráficos - Tomografia Computadorizada (Sem Regularização)




Figura 19: Evolução da convergência por número de iterações em TC.




Figura 20: Evolução da convergência ao longo do tempo em TC.




Figura 21: Reconstruções que atingiram o menor valor de função objetivo para os diferentes métodos.




Figura 22: Evolução da convergência por iteração para teste com 200 iterações.




Figura 23: Evolução da convergência ao longo do tempo para teste com 200 iterações.




Figura 24: Melhores reconstruções (que atingiram o menor valor de função objetivo) obtidas no teste com 200 iterações.




Figura 25: Comparação visual: Nesterov Busca Exata vs Gradientes Conjugados com tolerância de 10^{-4} .




Figura 26: Comparação visual: Nesterov Busca Exata vs Gradientes Conjugados com tolerância de 10^{-5} .

B.4 Gráficos - Tomografia Computadorizada (*Wavelets* e Variação Total)




Figura 27: *Grid-Search* para determinação do parâmetro de regularização $\gamma = 0.005$ em TC com *Wavelets*.




Figura 28: Diferença $\|x_k - x_{k-1}\|$ em TC com *Wavelets*.




Figura 29: Evolução de $F(x_k) - F^*$ em TC com *Wavelets*, demonstrando a instabilidade assintótica.




Figura 30: Evolução do PSNR em TC com *Wavelets*.




Figura 31: Melhores reconstruções obtidas (que minimizam a função objetivo) e qualidade visual em TC com *Wavelets*.




Figura 32: *Grid-Search* para determinação do parâmetro de regularização $\gamma = 0.005$ em TC com Variação Total.




Figura 33: Diferença $\|x_k - x_{k-1}\|$ em TC com Variação Total




Figura 34: Evolução de $F(x_k) - F^*$ em TC com Variação Total, ilustrando a instabilidade assintótica no ISTA Exato e FISTA Exato em comparação com FISTA Fixo.




Figura 35: Evolução do PSNR em TC com Variação Total.




Figura 36: Melhores reconstruções obtidas (que minimizam a função objetivo) e qualidade visual em TC com Variação Total.